2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 25

Larzabal, Juliana

Pedone Diez, Juliana

Sanchez, Santiago

1. Introducción

Nuestra base de datos proviene de la EPA (United States Environmental Protection Agency), la agencia federal estadounidense encargada de proteger la salud humana y el medio ambiente. En el sector del transporte, la EPA regula las emisiones y el consumo energético mediante el desarrollo de estándares rigurosos. El problema central que aborda este dominio es la necesidad de medir, comparar y transparentar la eficiencia energética del parque automotor frente a una industria en plena transición hacia la electrificación y con normativas ambientales cada vez más estrictas.

Para abordar este problema, trabajamos sobre el conjunto de datos “2025 Test Car List Data”. Este dataset contiene información de modelos de vehículos del año 2025 sometidos a ensayos para determinar su economía de combustible.

Cada año, la EPA proporciona datos sobre el consumo de combustible al Departamento de Energía (DOE), al Departamento de Transporte (DOT) y al Servicio de Impuestos Internos (IRS), a fin de que puedan administrar sus programas relacionados con el consumo de combustible.
El DOE y el DOT los emplean para las etiquetas obligatorias en los concesionarios y para verificar el cumplimiento de las normativas corporativas (CAFE).
El IRS los utiliza para administrar programas de impuestos a vehículos ineficientes ("Gas Guzzler Tax") y gestionar créditos fiscales para vehículos limpios.

El ensayo principal busca determinar la economía de combustible, la cual expresa cuánta distancia puede recorrer un vehículo utilizando una determinada cantidad de combustible. En Estados Unidos suele expresarse mediante *miles per gallon* (MPG), una medida de eficiencia donde un mayor valor implica que el vehículo puede recorrer una mayor distancia con la misma cantidad de combustible.

El consumo de un vehículo depende de múltiples factores: características del motor, masa, transmisión, sistema de tracción, combustible y condiciones de conducción. Para permitir una comparación justa, se utilizan procedimientos estandarizados de ensayo que simulan diferentes condiciones de conducción, tales como ciclos urbanos (FTP) o de autopista (HWY).

Cada fila del dataset representa una determinada configuración de vehículo sometida a ensayo, por lo que un mismo modelo puede aparecer en múltiples registros si existen diferencias en su motorización, transmisión o el ensayo realizado. Para identificar una configuración única de vehículo, la EPA utiliza la combinación de las variables: ***Veh Mfr Code + Test Vehicle ID + Test Veh Configuration***.

Entre las características técnicas registradas que afectan la economía de combustible se encuentran la cilindrada, cantidad de cilindros, potencia, tipo de combustible, transmisión, marchas, sistema de tracción, tecnologías de hibridación y peso (resumido en la Fig. 1).

Clase	Ejemplos	Interpretación
Identificación	fabricante, modelo, año.	Identifican la configuración ensayada.
Características del motor	cilindrada, cilindros, potencia	Describen el sistema de propulsión
Transmisión y tracción	tipo de transmisión, marchas, drive system	Describen cómo se transmite la potencia
Combustible	tipo de combustible	Fuente de energía utilizada
Condiciones de ensayo	procedimiento o ciclo de prueba	Características del ensayo realizado
Resultados	MPG, emisiones u otras medidas	Mediciones obtenidas durante los ensayos

Fig. 1: Forma de organizar toda la información contenida en las variables del dataset en categorías, junto con la interpretación.

Durante la etapa inicial de exploración del conjunto de datos, se identificaron diversas inconsistencias estructurales, valores nulos y registros atípicos (outliers) que requerían tratamiento para no distorsionar los resultados estadísticos. Dado que la limpieza y el preprocesamiento de los datos se llevaron a cabo de manera simultánea e integrada con el Análisis Exploratorio de Datos (EDA), todas las acciones correctivas implementadas —tales como la reasignación de tipos de datos, la gestión de registros desdoblados y el tratamiento de nulos y valores extremos— se detallan y justifican progresivamente a lo largo de la siguiente sección.

Para dar respuesta a los interrogantes planteados sobre este dominio de manera estructurada, el presente informe se organiza en las siguientes secciones:

1. Introducción: Presenta el contexto general del problema, el origen y la utilidad del dataset, así como los fundamentos técnicos necesarios para comprender cómo se evalúa la economía de combustible.

2. Análisis exploratorio de los datos (EDA) y Preprocesamiento: Aborda la evaluación profunda del conjunto de datos, analizando la granularidad, el alcance, la temporalidad, la confiabilidad y el comportamiento estadístico de las variables. Simultáneamente, documenta todas las tareas de limpieza y transformación aplicadas para garantizar la calidad de la base de datos.

3. Hipótesis y resolución: Constituye el núcleo analítico del trabajo. Aquí se formulan, evalúan y discuten seis hipótesis (dos univariadas, dos bivariadas y dos multivariadas) para comprobar el impacto que tienen las distintas características mecánicas y los entornos de conducción sobre la eficiencia energética y los parámetros de ensayo.

4. Conclusiones: Sintetiza los hallazgos principales obtenidos a partir de la validación de las hipótesis, vinculando los resultados matemáticos con el problema original de la industria automotriz y las normativas vigentes.

2. Análisis exploratorio de los datos

A medida que avanzamos con el análisis del dataset fuimos encontrando problemas o situaciones que debíamos modificar, no solo para un manejo más cómodo de la base, sino también para luego poder hacer una validación correcta de las hipótesis.
Para solucionarlo realizamos las operaciones de limpieza que consideramos necesarias. A continuación, junto con el análisis exploratorio, indicamos las acciones correctivas implementadas en la base y justificamos el por qué de cada una de ellas.

2.1 Tipos de datos

Comenzamos el análisis del dataset estableciendo la clasificación de cada una de las variables del mismo, definiendo si las mismas eran categóricas, nominales u ordinales, o numéricas, continuas o discretas. A continuación, en la Fig. 2, se verá una tabla con el resultado:

Variable	Clasificación Principal	Subtipo Específico
Model Year	Numérica	Discreta (Constante: 2025)
Vehicle Manufacturer Name	Categórica	Nominal
Veh Mfr Code	Categórica	Nominal
Represented Test Veh Make	Categórica	Nominal
Represented Test Veh Model	Categórica	Nominal
Test Vehicle ID	Categórica	Nominal
Test Veh Configuration #	Categórica	Nominal (Identificador)
Actual Tested Testgroup	Categórica	Nominal
Vehicle Type	Categórica	Nominal
Test Veh Displacement (L)	Numérica	Continua
Rated Horsepower	Numérica	Continua
# of Cylinders and Rotors	Numérica	Discreta

Engine Code	Categórica	Nominal
Tested Transmission Type Code	Categórica	Nominal
Tested Transmission Type	Categórica	Nominal
# of Gears	Numérica	Discreta
Transmission Lockup?	Categórica	Nominal (Binaria)
Drive System Code	Categórica	Nominal
Drive System Description	Categórica	Nominal
Transmission Overdrive Code	Categórica	Nominal
Transmission Overdrive Desc	Categórica	Nominal
Equivalent Test Weight (lbs.)	Numérica	Continua
Axle Ratio	Numérica	Continua
N/V Ratio	Numérica	Continua
Shift Indicator Light Use Cd	Categórica	Nominal
Shift Indicator Light Use Desc	Categórica	Nominal
Test Number	Categórica	Nominal (Identificador)
Test Originator	Categórica	Nominal (Binaria)
Analytically Derived FE?	Categórica	Nominal (Binaria)
ADFE Test Number	Categórica	Nominal (Identificador)
ADFE Total Road Load HP	Numérica	Continua
ADFE Equiv. Test Weight (lbs.)	Numérica	Continua
ADFE N/V Ratio	Numérica	Continua
Test Procedure Cd	Categórica	Nominal

Test Procedure Description	Categórica	Nominal
Test Fuel Type Cd	Categórica	Nominal
Test Fuel Type Description	Categórica	Nominal
Test Category	Categórica	Nominal
THC (g/mi)	Numérica	Continua
CO (g/mi)	Numérica	Continua
CO2 (g/mi)	Numérica	Continua
NOx (g/mi)	Numérica	Continua
PM (g/mi)	Numérica	Continua
CH4 (g/mi)	Numérica	Continua
N2O (g/mi)	Numérica	Continua
RND_ADJ_FE	Numérica	Continua
FE_UNIT	Categórica	Nominal (Constante)
FE Bag 1	Numérica	Continua
FE Bag 2	Numérica	Continua
FE Bag 3	Numérica	Continua
FE Bag 4	Numérica	Continua
DT-Inertia Work Ratio Rating	Numérica	Continua
DT-Absolute Speed Change Ratg	Numérica	Continua
DT-Energy Economy Rating	Numérica	Continua
Target Coef A (lbf)	Numérica	Continua
Target Coef B (lbf/mph)	Numérica	Continua

Target Coef C (lbf/mph**2)	Numérica	Continua
Set Coef A (lbf)	Numérica	Continua
Set Coef B (lbf/mph)	Numérica	Continua
Set Coef C (lbf/mph**2)	Numérica	Continua
Aftertreatment Device Cd	Categórica	Nominal
Aftertreatment Device Desc	Categórica	Nominal
Police - Emergency Vehicle?	Categórica	Nominal (Binaria)
Averaging Group ID	Categórica	Nominal
Averaging Weighting Factor	Numérica	Continua
Averaging Method Cd	Categórica	Nominal
Averging Method Desc	Categórica	Nominal

Fig. 2: Tabla que contiene la clasificación de todas las variables del dataset

A partir del resultado obtenido podemos ver que hay dos variables que son constantes en toda la base de datos. Una es *"Model Year"* que indica el año del modelo de vehículo (todos los registros son 2025, porque estamos sobre un dataset de dicho año). La otra es *"FE_Unit"*, esta representa la unidad de medida de la economía de combustible (que siempre es MPG).
Como ninguna de las dos variables aporta información valiosa decidimos eliminar ambas columnas, tal como se muestra en la sección 1.2.1 del notebook de jupyter.

Luego, como se ve en la sección 1.1.1 del código, chequeamos el tipo de cada variable. Encontramos que los únicos tipos usados en el dataset son float64 (hay 2), int64 (hay 9) y object (hay 56). Sin embargo, después de analizarlo, tomamos la decisión de cambiar algunos.

Cambiamos las variables *"Test Veh Configuration #"*, *"Transmission Overdrive Code"*, *"Shift Indicator Light Use Cd"*, *"Test Procedure Cd"* y *"Test Fuel Type Cd"* de int64 a object, ya que aunque están registradas numéricamente en el archivo original, estas variables representan códigos categóricos nominales sin orden ni magnitud matemática. Mantenerlas como enteros constituye una infracción de tipo de dato y distorsionaría los análisis estadísticos cuantitativos. Estos cambios fueron realizados en la sección 1.1.5 del código fuente.

También modificamos el tipo de las variables *“Transmission Lockup?”*, *“Analytically Derived FE?”*, y *“Police - Emergency Vehicle?”* de object a boolean. Al presentar únicamente dos valores ('Y' y 'N'), estas columnas constituyen variables binarias. Mapearlas a valores booleanos (True / False) permite expresar correctamente su naturaleza estadística y evita confusiones durante la manipulación y el análisis de los datos. Estos cambios fueron realizados en la sección 1.1.6 del código fuente.

Por último, modificamos el tipo de las variables *“Target Coef A (lbf)”*, *“Target Coef B (lbf/mph)”*, y *“Target Coef C (lbf/mph**2)”* de Str a float

2.2 Granularidad

A partir del análisis previo del dataset averiguamos que los vehículos se identifican mediante la clave EPA, de configuración única, y que los ensayos se identifican mediante la variable llamada Test Number, que también es única. Con esas dos variables se pueden definir valores muy relevantes para el análisis de los datos. Teniendo esto en cuenta calculamos cuántas filas posee el dataset, cuántas configuraciones únicas, filas totalmente duplicadas y Test Number repetidos hay, esto fue realizado en la sección 1.1.2 del código.

Haciendo estos cálculos pudimos observar que hay 4287 filas, pero sólo 1448 configuraciones únicas (es decir, vehículos de ensayo), lo que permite ver que a cada vehículo se le realizaron una cantidad distinta de ensayos. Algunas configuraciones tuvieron un sólo ensayo, mientras que otras tuvieron hasta 15 o 16. Este cálculo se puede ver en la misma sección (ensayo por configuración.)

También vimos que las filas totalmente duplicadas son 0, mientras que hay 273 Test Number repetidos. Si tomamos en cuenta que el Test Number es el identificador único del ensayo, esto podría indicar que sí hay filas repetidas, por más que no todas sus columnas sean iguales.

Al ver esta inconsistencia en los datos decidimos indagar más en el por qué, y descubrimos que ocurría porque las bases de datos relacionales "desdoblan" un registro cuando existe una relación de uno a muchos. Es decir, hubo un único ensayo físico, pero el vehículo poseía múltiples atributos para una misma categoría que no podían registrarse en una sola celda. En la sección 1.1.3 del notebook se puede ver que esto ocurría específicamente con las columnas Set Coef A, B y C (Coeficientes de dinamómetro), como se puede ver en la Fig. 2; y con Aftertreatment Device Cd y Desc (Sistemas de postratamiento), como se observa en la Fig. 3.

Test Number: NGMX10069151

	Set Coef A (lbf)	Set Coef B (lbf/mph)	Set Coef C (lbf/mph**2)
1093	13,390	-0,16720	0,024970
1094	13,030	0,07050	0,022920
1095	18,260	-0,25130	0,025700

Test Number: NGMX10069153

	Set Coef A (lbf)	Set Coef B (lbf/mph)	Set Coef C (lbf/mph**2)
1096	18,260	-0,25130	0,025700
1097	13,030	0,07050	0,022920
1098	13,390	-0,16720	0,024970

Fig. 2: Muestra 2 tablas distintas en las que se puede ver como para un mismo Test Number hay más de una fila con distintos valores en las columnas Set Coef A, B y C

Test Number: NFEX10067550

	Aftertreatment Device Cd	Aftertreatment Device Desc
782	TWC	Three-way catalyst
783	OT	Other

Test Number: NFEX10067551

	Aftertreatment Device Cd	Aftertreatment Device Desc
784	TWC	Three-way catalyst
785	OT	Other

Test Number: NFEX10067679

	Aftertreatment Device Cd	Aftertreatment Device Desc
786	OT	Other
787	TWC	Three-way catalyst

Fig. 3: Muestra 3 tablas distintas en las que se puede ver como para un mismo Test Number hay más de una fila con distintos valores en las columnas Aftertreatment Device Cd y Desc

Para solucionar esas filas “repetidas” hicimos lo siguiente (también realizado en la sección 1.1.3):

- **Para los sistemas de postratamiento:** agrupamos por Test Number y concatenamos los textos. Por ejemplo, en lugar de dos filas, te quedas con una sola fila donde el dispositivo de postratamiento diga “Three-way catalyst, Other”. Así conservamos todo el equipamiento del vehículo.
- **Para los coeficientes A, B y C:** optamos por promediar los coeficientes.

Como se puede ver en la sección 1.1.4 del notebook también analizamos cuántos ensayos se realizaron por cada categoría. En la Fig. 4 se observa que la mayoría de ensayos fueron FTP (Federal Test Procedure, este simula el comportamiento de **conducción urbana**) o HWY (Highway Fuel Economy Test, que simula el comportamiento de **conducción en carretera o autopista**).

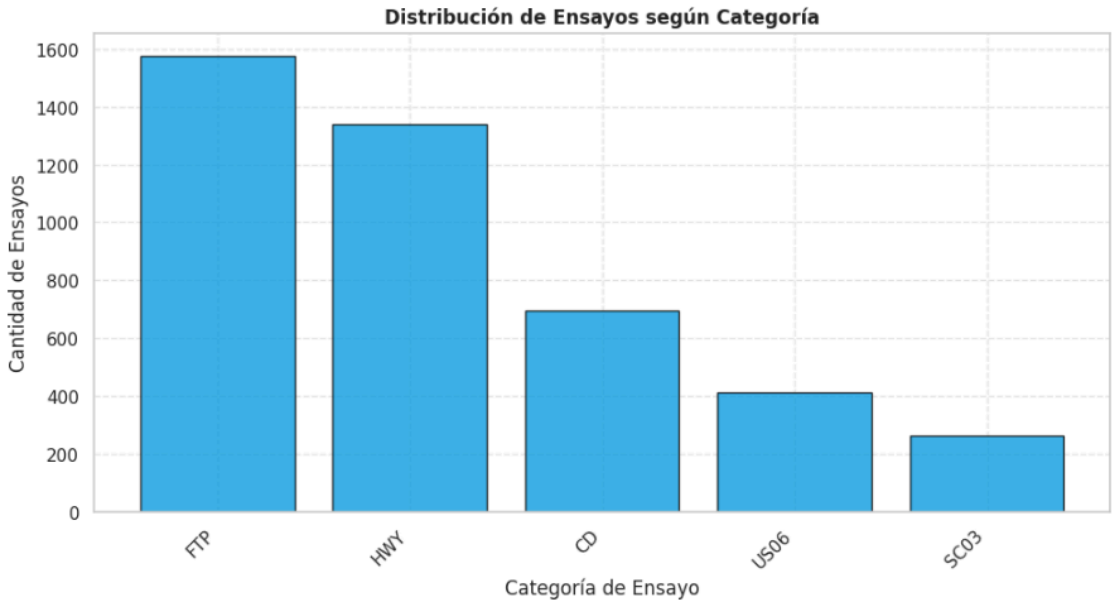


Fig. 4: Gráfico de barras que compara la cantidad de ensayos que se realizaron por cada categoría

2.3 Alcance

El muestreo de datos del dataset fue realizado de manera **no probabilística**, específicamente un **muestreo intencional** o por juicio (purposive sampling).

Los datos no se obtuvieron seleccionando vehículos físicos al azar. Los registros provienen de pruebas exigidas y reguladas por la Environmental Protection Agency (EPA) a los fabricantes automotrices. Tanto la EPA como las marcas seleccionan deliberadamente configuraciones

vehiculares muy específicas (identificadas mediante el grupo de ensayo o familia de motor) que necesitan ser certificadas para su venta en el año modelo 2025.

Como el objetivo del conjunto de datos es determinar las estimaciones oficiales de economía de combustible y el cumplimiento de normativas de emisiones, los ingenieros eligen intencionalmente el vehículo físico exacto ("Test Vehicle ID") que representa de manera técnica y legal a cada configuración comercial.

2.4 Temporalidad

El análisis de la temporalidad y espacialidad de este conjunto de datos revela que se trata de un **estudio transversal (cross-sectional)** estático y no de una serie de tiempo, debido a la ausencia de marcas temporales y geográficas específicas a nivel de registro.

El conjunto de datos carece de granularidad temporal; es decir, no existe ninguna columna (como un timestamp o test_date) que indique el día, mes o la hora exacta en la que un vehículo fue subido al dinamómetro. La única referencia temporal interna es la variable *“Model Year”*,que como ya dijimos indica el año modelo 2025. Por la naturaleza de la industria automotriz, estos ensayos suelen realizarse durante el año previo o a principios del año de lanzamiento para obtener las certificaciones necesarias.

El dataset no contiene datos geoespaciales (latitud, longitud, ciudad o estado). Todo el marco regulatorio corresponde exclusivamente a Estados Unidos, dado que las pruebas son reportadas a la Environmental Protection Agency (EPA) de dicho país. Sin embargo, la ubicación geográfica exacta de dónde se realizó cada prueba pierde total relevancia técnica: los ensayos se realizan en condiciones de laboratorio estandarizadas que simulan escenarios de conducción. El objetivo de usar un dinamómetro en lugar de una calle real es, precisamente, eliminar las variables geográficas y climáticas (altitud, temperatura ambiente, estado del pavimento, viento) para que todos los vehículos sean comparables bajo un mismo estándar inmutable.

2.5 Confiabilidad

Los datos aportados por el dataset son altamente confiables por su naturaleza oficial y metodológica, pero exigen un preprocesamiento cuidadoso para no sacar conclusiones matemáticas erróneas. Al tratarse de información regulatoria y técnica, su "ruido" no proviene de errores de medición, sino de la complejidad del dominio.

Por ejemplo, en muchos conjuntos de datos, tener columnas con 95% de nulos o filas con identificadores repetidos indica corrupción o mala recolección. En este caso, es un comportamiento diseñado y confiable. Las columnas vacías, que serán analizadas más adelante,

responden a protocolos condicionales donde ciertos datos simplemente no se aplican a ese tipo de ensayo.

2.6 Outliers

Para el análisis de los outliers decidimos enfocarnos en las variables que nos interesan para las hipótesis, ya que de otra forma se hubiese hecho muy extenso teniendo tantas variables.

En el ámbito categórico, un outlier se define como una categoría con una frecuencia extremadamente baja, lo que indica condiciones o diseños muy poco comunes:

- **Test Fuel Type Description (Combustible):** La gasolina estándar ("Tier 2 Cert Gasoline", 75.48%) y la electricidad (15.26%) dominan el mercado. Los outliers aquí son los combustibles experimentales, alternativos o regionales específicos. El Hidrógeno ("Hydrogen 5", 0.23%), el Etanol ("E85", 0.28%) y las gasolinas grado "CARB LEV3 E10" (apenas 1 a 2 registros) representan tecnologías o certificaciones de nicho que se alejan por completo del estándar. Esto fue realizado en la sección 1.1.7.1 del código y se puede observar en la Fig. 5.

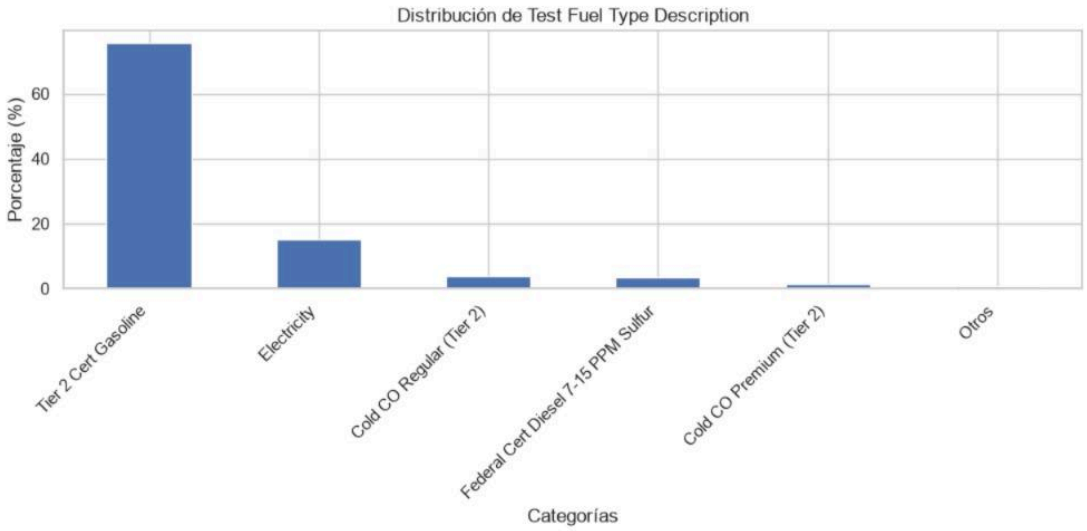


Fig. 5:

- **Drive System Code (Tracción):** Los sistemas AWD (A), delantera (F), trasera (R) y 4WD (4) tienen una distribución saludable. Sin embargo, el código "P" (Part-time 4WD, tracción a las 4 ruedas conectable) es un outlier categórico, apareciendo solo en el 1.7% de los ensayos, confinado estrictamente a ciertos vehículos de trabajo o todoterrenos puros. Lo cual fue realizado en la sección 1.1.7.2 del código y se puede observar en la Fig. 6.

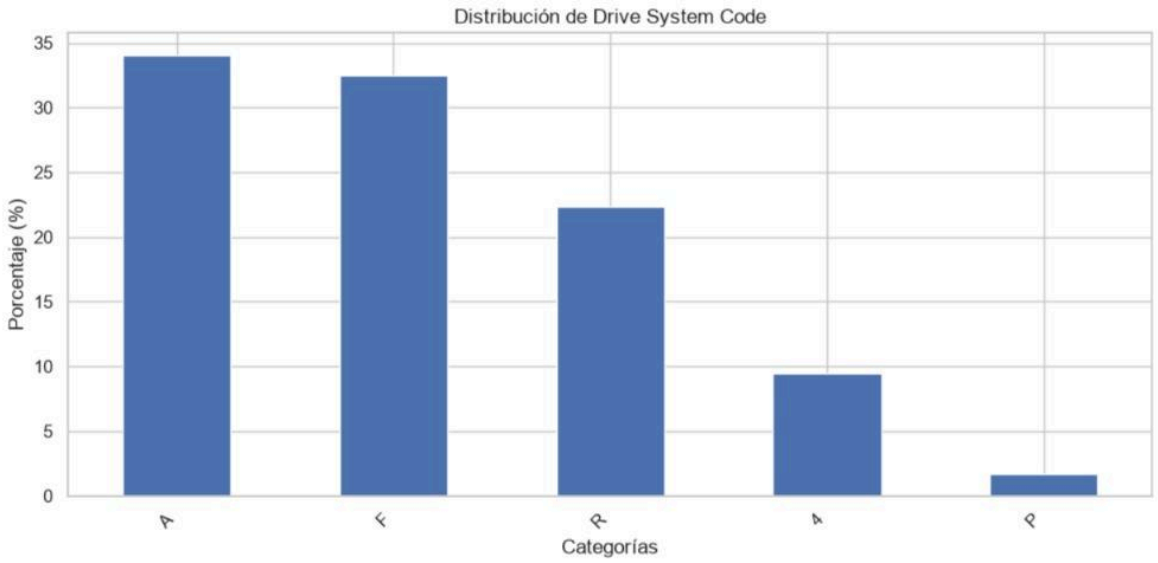


Fig. 6: Gráfico de barras que representa la distribución porcentual de los códigos del sistema de tracción

- **Test Category y Vehicle Type:** No presentan outliers. Todas las categorías ("FTP", "HWY", "CD", etc. para ensayos, y "Truck", "Car", "Both" para vehículos) poseen una participación masiva y balanceada superior al 6%. Esto se puede observar en las secciones 1.1.7.3 y 1.1.7.4 del código. En la Fig. 7 se puede observar la distribución de Test Category, y en la Fig. 8 la distribución de Vehicle Type.

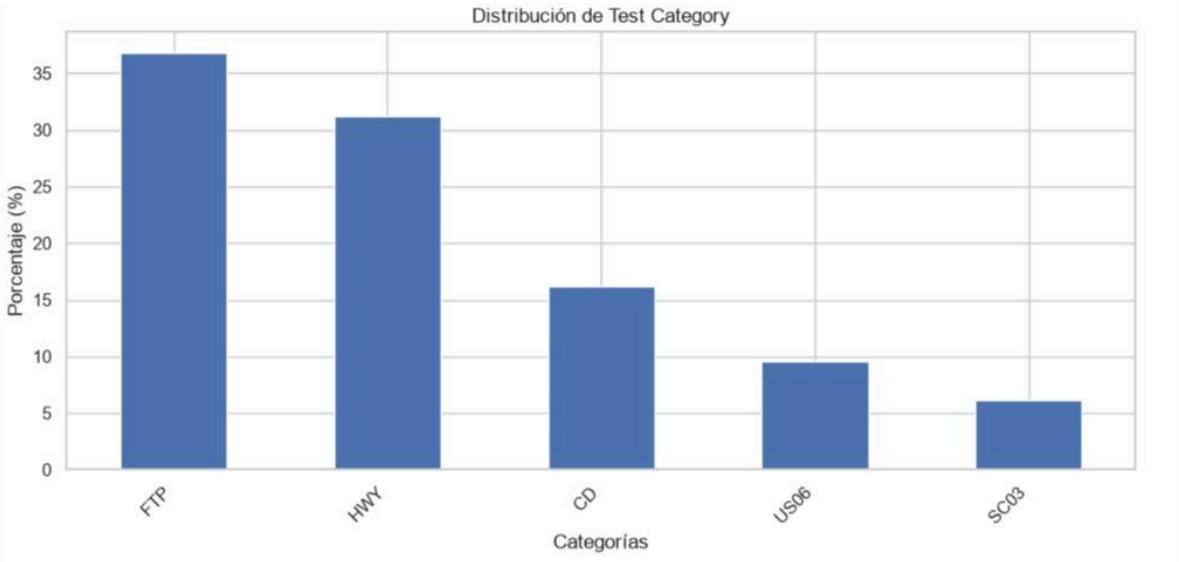


Fig. 7: Gráfico de barras que representa la frecuencia porcentual de las categorías de prueba

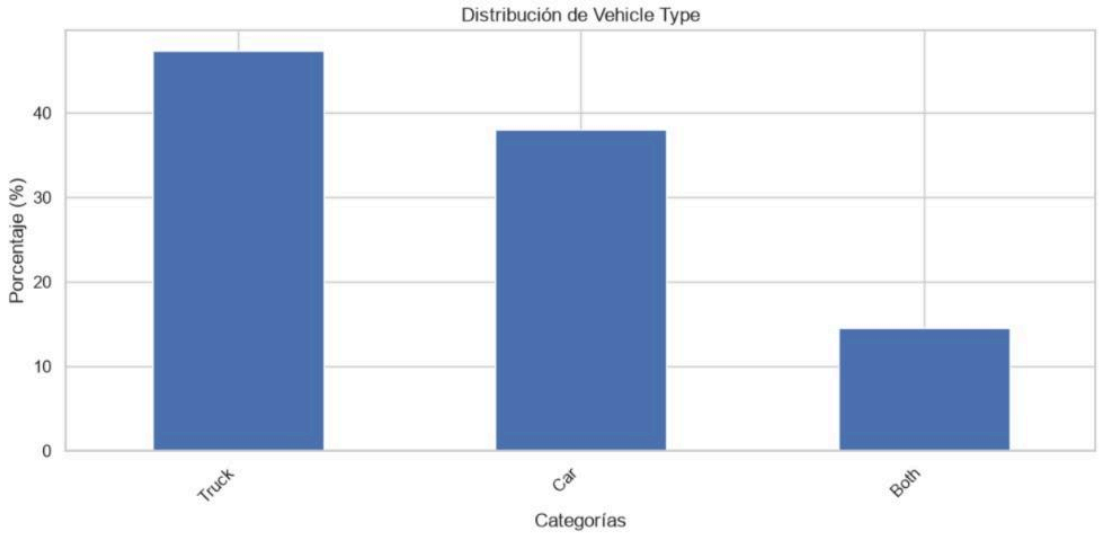


Fig. 8: Gráfico de barras que representa la distribución porcentual del tipo de vehículo

- **Tested Transmission Type (Transmisión):** Los *outliers* son los tipos de transmisión que tienen una frecuencia de aparición extremadamente baja, demostrando cuáles son las tecnologías en desuso o de un nicho muy particular en 2025. Las transmisiones "Automatic" (38%) y "Semi-Automatic" (28%) dominan absolutamente los ensayos, sumando más del 66% del dataset. Las CVT estándar (11.4%) y las Manuales Automatizadas Selectables (11.3%) son también bastante comunes. Los outliers encontrados corresponden a Manual (Tradicional), Other (Otros), y Automated Manual (sin especificar 'Selectable'). Todo lo mencionado fue calculado en la sección 1.1.7.5 y se puede observar su distribución en la Fig. 9

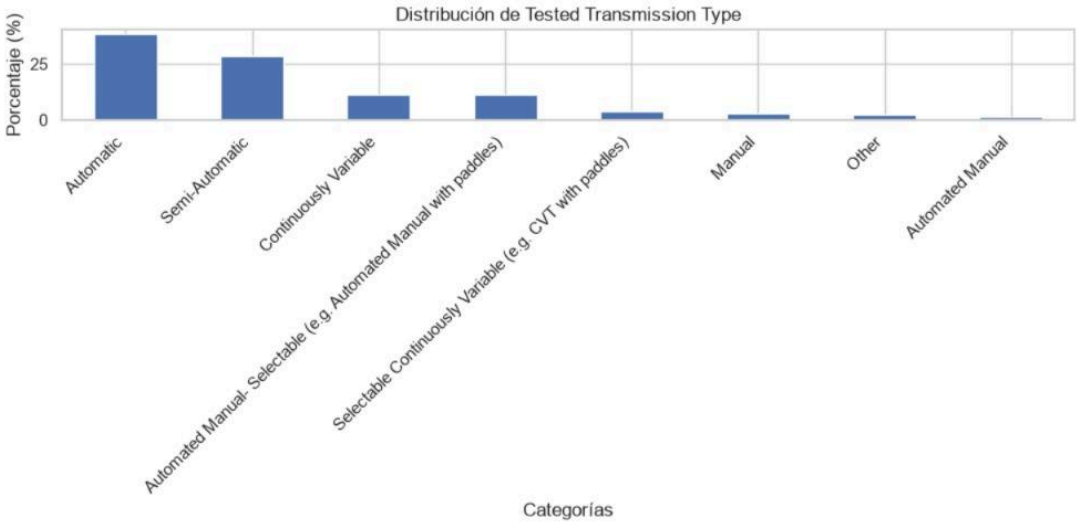


Fig. 9: Gráfico de barras que representa la distribución porcentual del tipo de transmisión

Para las variables numéricas, el cálculo de los límites del Rango Intercuartílico (IQR) y la visualización de los diagramas de caja (boxplots) exponen lo siguiente:

- **RND_ADJ_FE (Economía de Combustible):** Es la variable con el comportamiento atípico más pronunciado (8.07% de la muestra cae fuera de los límites estadísticos "normales"). Esto se puede visualizar en la Fig. 10 que está a continuación. La mayoría de los vehículos se agrupan entre 24 y 43 MPG. Sin embargo, existen dos tipos de outliers:
    - *Outliers lógicos/tecnológicos:* Los vehículos eléctricos generan una enorme cola derecha en la distribución estadística natural, alcanzando eficiencias que superan las 100, 150 y hasta 200 MPG equivalentes.
    - *Outliers de error/codificación:* Existen mediciones artificialmente marcadas como 9999.99 MPG o 0 MPG, las cuales actúan como códigos regulatorios de exención o variables analíticas, los mismos fueron removidos.

  Todo lo mencionado de esta variable fue realizado en la sección 1.1.9.1 del código fuente.

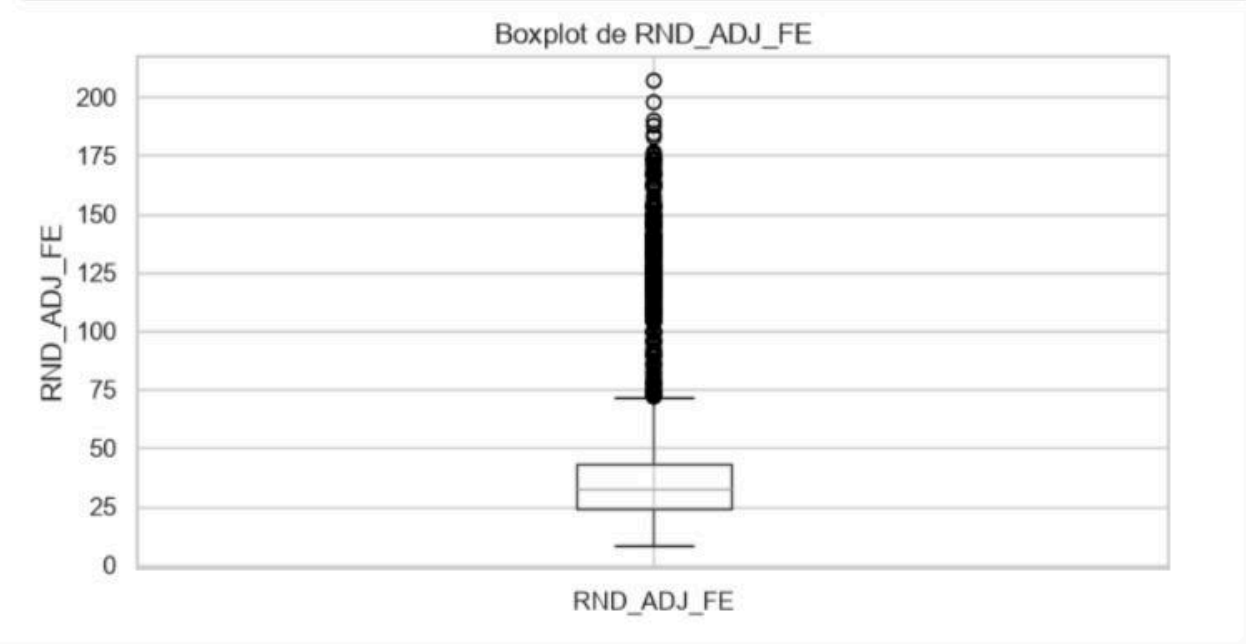


Fig. 10: Boxplot que representa la economía de combustible. Muestra una distribución fuertemente asimétrica hacia la derecha, con una gran cantidad de valores atípicos de alto rendimiento superiores a 75 MPG.

- **Equivalent Test Weight (Peso Equivalente de Ensayo):** La masa de los vehículos es muy consistente, oscilando normalmente entre 4000 y 5500 libras. Posee una cantidad ínfima de outliers (0.54% de los datos). Estos corresponden a vehículos de hiper-peso, específicamente aquellos que superan el límite superior estadístico de 7750 libras, alcanzando hasta 9000 libras (probablemente camionetas de la serie Heavy Duty y

grandes SUVs eléctricos que cargan baterías masivas). El análisis mencionado se realizó en la sección 1.1.9.2 del notebook. A continuación, en la Fig. 11 se puede visualizar.

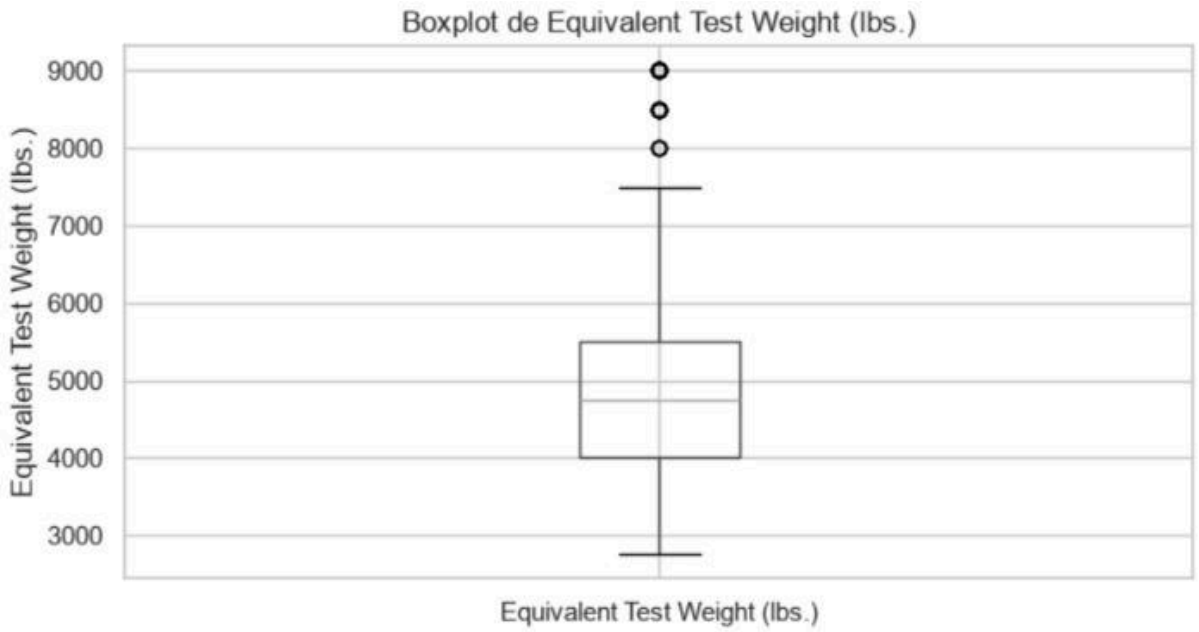


Fig. 11: Boxplot que representa la distribución del peso equivalente de prueba en libras.
El 50% central de la muestra oscila entre 4000 y 5500 lbs,
con valores atípicos superiores llegando a 9000 lbs.

- **Target Coef A (Resistencia al avance):** Presenta un 2.85% de outliers, todos ubicados en el extremo superior. Mientras que la resistencia aerodinámica base suele no superar las 69 lbf, un pequeño grupo de vehículos (seguramente los mismos furgones grandes o pick-ups 4x4 muy elevadas del suelo) rompe la barrera estadística, superando las 90 lbf de fricción y resistencia contra el dinamómetro.

// boxplot y análisis de esa variable en sección 1.1.9.3

- **Test Veh Displacement (L) (Cilindrada):** El primer hallazgo crucial en esta variable es que contiene **valores atípicos artificiales** asociados a los vehículos eléctricos. En los registros de la EPA, muchos eléctricos aparecen con cilindradas de 99.999 L o 0.001 L a modo de *placeholder* (relleno de base de datos). Eliminamos estos valores extremos y podemos, ver que siguen una distribución normal (entre 2.0 L y 3.4 L) con algunos outliers reales, cualquier motor por encima de los 5.61 L se considera un valor atípico en este dataset. A continuación, en la Fig. 12, se puede ver un boxplot que representa dicho análisis, el mismo está dentro de la sección 1.1.9.4 del código.

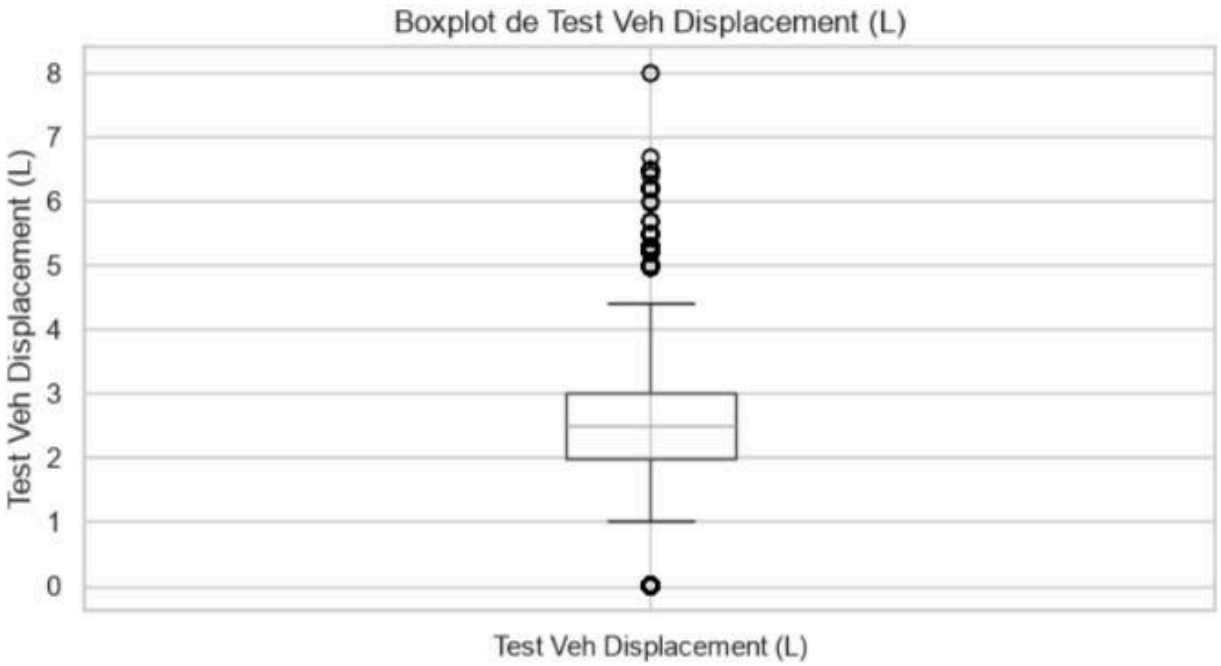


Fig. 13: Boxplot que representa el desplazamiento del motor en litros. La mediana se ubica en torno a los 2.5 L, presentando valores atípicos tanto en el extremo superior como inferior.

- **Rated Horsepower (Potencia):** A diferencia de la cilindrada, la potencia aplica a todos los vehículos (tanto eléctricos como de combustión). Aquí los *outliers* nos muestran el segmento de hiperautos y eléctricos de ultra-alto rendimiento. El 50% central del mercado se mueve entre los 201 HP y los 409 HP, y cualquier vehículo que supere los 721 HP es clasificado como *outlier* (son apenas un 3.2% del total de pruebas). Este análisis se encuentra dentro de la sección 1.1.9.5 del código fuente, y a continuación se puede ver la Fig. 14 que lo representa..

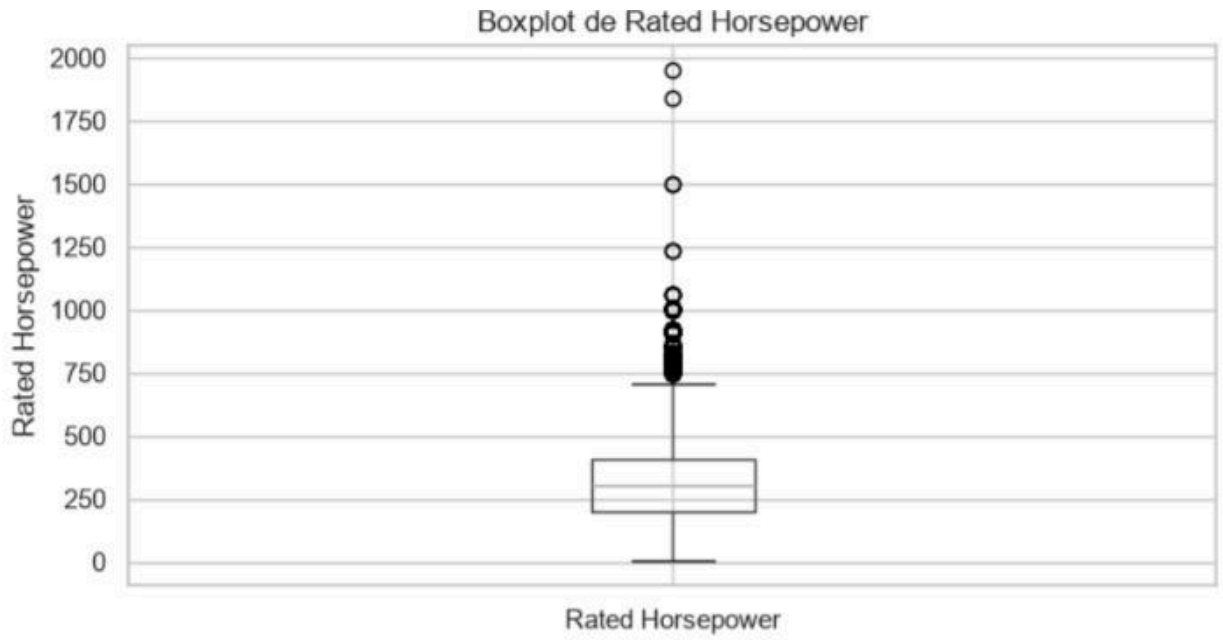


Fig. 14: Boxplot que representa la distribución de la potencia nominal mediante diagrama de caja. Se evidencia una alta concentración de datos y una marcada asimetría por numerosos valores atípicos que alcanzan los 2000 hp.

2.7 Valores nulos

Al igual que con los outliers, el análisis de los valores nulos lo enfocamos en las variables que luego son utilizadas en las hipótesis.

El análisis sobre dichas variables reveló que la calidad de los datos para la mayoría de esos campos es excepcionalmente alta, sin presentar valores en blanco, ocultos o no definidos, a excepción de una sola variable.

La única variable de las analizadas que contiene nulos es **RND_ADJ_FE** (Economía de combustible ajustada/redondeada). Se registró una cantidad de nulos de 221 registros (5.15% del dataset). Este cálculo también fue realizado dentro de la sección 1.1.9.1 anteriormente mencionada.

El 5.15% de ensayos que carecen de este valor **no parece ser un error aleatorio**, sino que responde a la naturaleza de las pruebas. Al cruzar los registros nulos con la categoría de la prueba (Test Category), observamos que más de la mitad (130 casos) corresponden a la categoría de ensayo CD (Charge-Depleting). Los ensayos Charge-Depleting son exclusivos de los vehículos híbridos enchufables (PHEV) cuando operan en modo puramente eléctrico agotando la batería. En este modo de operación no están consumiendo combustible líquido tradicional, lo

que suele derivar en la ausencia de cálculo de la variable MPG combinada de combustible en esa fila específica.

También hay que mencionar que la variable Test Veh Displacement, aunque no posee nulos técnicos, posee "placeholders" artificiales como 99.999 L y 0.001 L para los autos eléctricos (mencionados en la sección de outliers) que se podrían considerar cómo **nulos ocultos**. Lo mismo sucede con los outliers extremos de RND_ADJ_FE. Estos valores fueron limpiados en las secciones correspondientes a cada variable, 1.1.9.4 y 1.1.9.1 respectivamente.

Si expandimos el análisis a otras variables se pueden encontrar columnas que están diseñadas para registrar información que solo aplica a una minoría muy reducida de casos, por lo que presentan un **gran porcentaje de nulos**.

Entre ellas encontramos a las variables de ADFE (Analytically Derived Fuel Economy) que incluyen 4 columnas ADFE Test Number, ADFE Total Road Load HP, ADFE Equiv. Test Weight (lbs.) y ADFE N/V Ratio.
Estas cuatro columnas almacenan información exclusiva para los casos en los cuales la economía de combustible se obtiene mediante un procedimiento analíticamente derivado. Esto significa que, en lugar de poner el vehículo físico a rodar en el dinamómetro para medir el consumo, la EPA permite derivar el resultado matemáticamente basándose en un vehículo "hermano" de la misma familia, ajustando variables como el peso o la resistencia al avance. Como la inmensa mayoría de las configuraciones requieren ensayos físicos directos, estos campos quedan vacíos en el 95% de los casos.

También están las variables de Averaging (Promediado), con las columnas Averaging Group ID, Averaging Weighting Factor, Averaging Method Cd y Averging Method Desc.
Estas variables son específicas de ensayos cuyos resultados pueden combinarse. Esto ocurre en escenarios regulatorios muy particulares donde un fabricante ensaya múltiples variantes de una misma plataforma y pondera sus resultados para obtener un promedio representativo de esa familia de vehículos. Al ser un procedimiento excepcional que solo aplica a menos del 2% del dataset, es natural que estas columnas encabecen la lista de valores nulos.

Dado que los nulos en estas variables representan un "No Aplica" en lugar de "Información Perdida" (Missing Completely at Random), **no se debe imputar ni rellenar estos valores** con medias o medianas. Es por eso que decidimos **eliminar estas columnas por completo**, ya que sólo aportan ruido al modelo, esto fue realizado en la sección 1.2.2.

3. Hipótesis y resolución

3.1. Hipótesis 1 Univariada:

3.1.1. Definición de la hipótesis

"La gasolina certificada ('Tier 2 Cert Gasoline') es el combustible primario en más del 60% de los ensayos registrados para el año 2025."

Según el diccionario de datos, existen 11 categorías de combustible y, si bien la electricidad ("Electricity") se encuentra entre los grupos principales junto con el diésel, las pruebas de gasolina dominan históricamente las listas de la EPA. Como la EPA debe certificar cada configuración de tren motriz, y los vehículos de combustión interna suelen tener más variaciones de configuración (como múltiples iteraciones de transmisión y marchas para un mismo motor), es esperable que generen un volumen mucho mayor de registros en comparación con los vehículos 100% eléctricos (que suelen tener una o dos configuraciones simples de motor a batería).

Validar esta hipótesis demostraría que el volumen de filas en el dataset representa el esfuerzo de certificación técnica, no la cuota de mercado ni la oferta real en concesionarios. Si más del 60% de los registros corresponden a "Tier 2 Cert Gasoline", calcular promedios directos sobre el dataset (como el promedio general de emisiones o de economía de combustible) arrojará resultados fuertemente sesgados hacia los motores de combustión. Esto obliga a los científicos de datos a agrupar o ponderar los registros por modelo antes de inferir tendencias del parque automotor.

Además, si la hipótesis es cierta, justificaría la necesidad de aplicar técnicas de reducción de dimensionalidad o agrupación (clustering) para los vehículos a gasolina en fases de análisis. Esto permite argumentar por qué tiene sentido unir cinco registros de un mismo modelo a gasolina en una sola fila promedio para poder compararlo de manera justa contra un modelo eléctrico que solo tiene un registro en la base de datos. Esto fue realizado dentro del análisis del dataset, en la sección ... del informe, y en la ... del notebook.

3.1.2. Estrategia de abordaje

Para abordar la validación de esta hipótesis, se definió como objeto de estudio la variable categórica nominal *“Test Fuel Type Description”*, la cual identifica el tipo de energía o combustible utilizado en cada evaluación de laboratorio. Dado que el objetivo es comprobar si la proporción de ensayos con gasolina certificada supera un umbral específico (60%), la técnica estadística seleccionada es una **prueba Z de hipótesis sobre una proporción** (de una muestra,

unilateral derecha). El uso de esta prueba paramétrica basada en la aproximación a la normalidad se justifica por el gran tamaño de la muestra del dataset (n > 1000), lo cual supera ampliamente las condiciones requeridas de éxito y fracaso.

El procedimiento estadístico se estructuró bajo el siguiente esquema metodológico:

- **Formulación de hipótesis:** Se definió como "éxito" a los registros cuyo valor sea 'Tier 2 Cert Gasoline'.
    - Hipótesis Nula (H_0): $p \leq 0.60$ (La gasolina certificada representa el 60% o menos de los ensayos registrados).
    - Hipótesis Alternativa (H_1): $p > 0.60$ (La gasolina certificada representa más del 60% de los ensayos registrados).
- **Nivel de significancia:** Se estableció un umbral de $\alpha = 0.05$ (5%), estándar para este tipo de análisis.
- **Ejecución y regla de decisión:** Mediante el cálculo de la proporción muestral observada sobre el total de ensayos, se obtendrá el estadístico Z y su respectivo p-valor (utilizando herramientas de Python). Si el p-valor resulta estrictamente menor a 0.05, se rechazará H_0, confirmando estadísticamente la hipótesis planteada.

Como consideración respecto a la granularidad de la base de datos, es importante aclarar que el análisis se ejecuta sobre la totalidad de los registros (ensayos) y no tras un filtrado previo de configuraciones únicas de vehículos. Esta decisión responde directamente a la redacción de la hipótesis y al contexto del dominio: se busca medir la preponderancia en el volumen de las pruebas impuestas por los estándares de la EPA, donde un mismo vehículo de combustión suele generar múltiples filas al ser sometido a diversos ciclos de ensayo.

Toda la estrategia mencionada es llevada a cabo en la Sección 2.1.1 del código fuente.

3.1.3. Resultados obtenidos y discusión

Al ejecutar el análisis sobre el conjunto de datos, el recuento de frecuencias reveló que la categoría “Tier 2 Cert Gasoline” se encuentra presente en el 75.48% de los ensayos registrados. Al someter esta proporción muestral a la prueba Z de hipótesis unilateral derecha con un umbral esperado del 60%, se obtuvo un p-valor prácticamente nulo (p-valor < 0.05) y un estadístico Z ampliamente superior al valor crítico. Por consiguiente, se rechaza la hipótesis nula.

En base a esta evidencia estadística, **la hipótesis es confirmada**: la gasolina certificada es el combustible primario en más del 60% de los ensayos de laboratorio para el año modelo 2025.

Esta confirmación tiene profundas implicancias metodológicas para el resto del análisis. Como se anticipó en la formulación de la hipótesis, este gran predominio no refleja necesariamente una

cuota de mercado en las calles, sino el enorme volumen de esfuerzo de certificación exigido por la EPA. Los vehículos de combustión interna requieren iterar a través de múltiples combinaciones de configuraciones mecánicas (distintas cajas de cambio, relaciones de ejes, tracciones) y diversos ciclos de ensayo, generando un abultado número de registros por cada modelo base, algo que no ocurre con la misma frecuencia en los vehículos eléctricos.

Comprender este sesgo estructural justifica técnicamente la necesidad de aplicar agrupaciones (clustering) o ponderar los promedios por modelo único al momento de inferir conclusiones generales sobre el parque automotor. De no hacerlo, cualquier cálculo directo (como el promedio global de consumo o emisiones) estaría fuertemente desviado hacia el rendimiento de la gasolina, invisibilizando el impacto real de las nuevas tecnologías electrificadas.

En la Fig. 15 se observa la distribución porcentual de los ensayos según el tipo de combustible utilizado. calculada en la sección 3.1.1 del código fuente. Obsérvese que la categoría *"Tier 2 Cert Gasoline"* supera ampliamente la línea punteada roja, la cual marca el umbral crítico del 60% establecido en la hipótesis, confirmando de manera visual el predominio absoluto de este combustible frente a las demás alternativas.

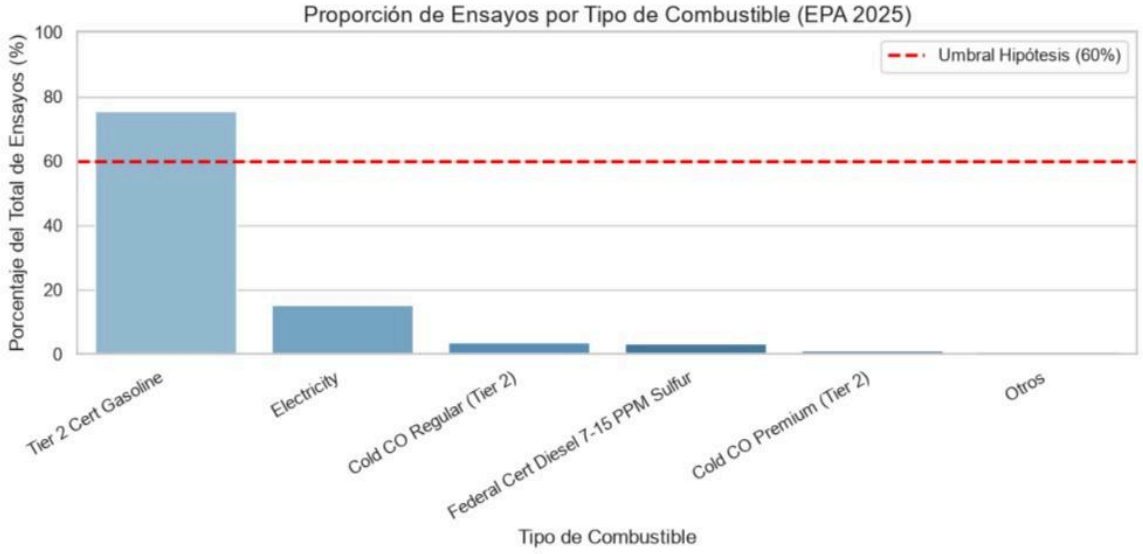


Fig. 15: Gráfico de barras que compara la cantidad de ensayos que se realizaron por cada tipo de combustible

3.2. Hipótesis 2 Univariada:

3.2.1. Definición de la hipótesis

"La mayoría de las configuraciones de vehículos a combustión alcanzan al menos 25 MPG de economía de combustible en condiciones de conducción urbana." (Planteada en el enunciado)

Esta hipótesis plantea que, al aislar los registros de los vehículos que utilizan combustibles fósiles (excluyendo a los eléctricos) y observar exclusivamente los resultados obtenidos en las pruebas de conducción urbana (como el ciclo FTP), más del 50% de las configuraciones ensayadas registran un valor de economía de combustible (RND_ADJ_FE) igual o superior a las 25 millas por galón (MPG). En términos simples, propone que la industria automotriz de combustión ha logrado estandarizar un rendimiento base de 25 MPG para el exigente entorno del tráfico de la ciudad.

Comprobar esta métrica permite establecer cuál es el estándar de eficiencia real de los motores de combustión interna para el año modelo 2025. Si se demuestra que la mayoría no logra superar la barrera de las 25 MPG en ciudad (el entorno donde más energía se desperdicia por las inercias de frenar y arrancar), se evidencia un estancamiento en el desarrollo de la combustión tradicional, justificando técnicamente por qué los fabricantes están forzados a transicionar hacia plataformas híbridas.

Validar esta hipótesis también es clave para las finanzas personales. Permite al consumidor calcular si su gasto mensual base está garantizado por este estándar o si la ineficiencia urbana de la combustión justifica asumir el costo extra de comprar un vehículo híbrido o eléctrico.

3.2.2. Estrategia de abordaje

Para evaluar si la mayoría de las configuraciones de vehículos a combustión alcanzan al menos 25 MPG en ciclo urbano, la estrategia metodológica inicia con un filtrado y estructuración rigurosa del conjunto de datos.

Empezamos por aislar los vehículos de combustión interna (excluyendo las motorizaciones cien por ciento eléctricas) y se conservan únicamente los ensayos correspondientes al ciclo urbano o de ciudad (FTP o City). Dado que el objetivo es analizar la configuraciones y no el volumen total de pruebas de laboratorio, se eliminan los registros duplicados conservando una única fila por modelo mediante la clave compuesta definida por la normativa (Veh Mfr Code + Test Vehicle ID + Test Veh Configuration #).

Sobre esta muestra representativa de configuraciones únicas, se ejecuta un análisis exploratorio de la variable continua de economía de combustible (RND_ADJ_FE). Mediante herramientas gráficas (histogramas y diagramas de caja) y la prueba analítica de Shapiro-Wilk, se evalúa la tendencia central, la dispersión, la asimetría y la presencia de valores atípicos, lo cual brinda contexto sobre el comportamiento general del rendimiento urbano.

Para la contrastación formal de la hipótesis, la variable continua se transforma en una variable dicotómica (tipo Bernoulli). Se define como "éxito" a toda configuración cuyo rendimiento sea

igual o superior al umbral de 25 MPG. Al buscar comprobar si esta condición representa a "la mayoría" (p > 0.50), la técnica estadística seleccionada es la prueba Z para una proporción (unilateral derecha).

El esquema de decisión estadístico se estructura bajo los siguientes parámetros:

- **Formulación de hipótesis:**
  - Hipótesis Nula (H_0): $p \leq 0.50$ (El 50% o menos de las configuraciones de combustión interna alcanzan las 25 MPG en ciudad).
  - Hipótesis Alternativa (H_1): $p > 0.50$ (Más del 50% de las configuraciones de combustión interna alcanzan o superan las 25 MPG en ciudad).
- **Nivel de significancia:** Se establece un umbral estándar de $\alpha = 0.05$ (5%).
- **Regla de decisión:** Se calculará la proporción muestral observada y su estadístico Z asociado. Si el p-valor resultante es estrictamente menor a 0.05 y la proporción observada es superior a 0.50, se rechazará la hipótesis nula, confirmando estadísticamente la validez de la hipótesis planteada.

Toda la estrategia mencionada es llevada a cabo en la Sección 2.1.2 del código fuente.

3.2.3. Resultados obtenidos y discusión

Al ejecutar el preprocesamiento y aislar las configuraciones únicas de combustión interna, el análisis exploratorio inicial de la variable RND_ADJ_FE mediante histogramas y diagramas de caja evidenció una marcada asimetría en la distribución de los datos. Esta observación visual fue corroborada por la prueba analítica de Shapiro-Wilk, la cual arrojó un p-valor mucho menor que 0.5, confirmando que el rendimiento de combustible en ciclo urbano no sigue una distribución normal y presenta un sesgo significativo.

Al transformar la variable continua en la condición dicotómica de interés, el recuento arrojó que 651 sobre un total de 1088 configuraciones únicas logran un rendimiento igual o superior a las 25 MPG. Al someter esta proporción a la prueba Z unilateral derecha, se obtuvo un estadístico Z de 6.6171.

Dado que el p-valor obtenido resulta menor al nivel de significancia del 5% ($\alpha = 0$) y la proporción muestral supera el umbral del 50%, se rechaza la hipótesis nula. Por consiguiente, **la hipótesis es confirmada**: existe evidencia estadística suficiente para afirmar que la mayoría de las configuraciones a combustión alcanzan al menos 25 MPG en conducción urbana.

Aunque no se conozca exactamente cuántos vehículos alcanzan los mejores resultados, esta prueba permite evaluar qué tan eficientes pueden ser los motores tradicionales a combustible

durante la conducción en ciudad en los modelos del año 2025. Los resultados muestran que algunos tipos de vehículos, como los que tienen motores más grandes, mayor potencia o tracción en las cuatro ruedas, hacen que el consumo promedio sea más elevado. Esto se debe a que suelen ser más pesados y necesitan más energía para detenerse y volver a arrancar constantemente, como ocurre en el tránsito urbano. Por lo tanto, estos vehículos consumen más combustible y reducen el rendimiento general de los automóviles que utilizan motores a combustión.

En la Fig. 16 se observa la distribución de los valores de la variable continua *"RND_ADJ_FE"*, según se genera la sección 3.1.2 del código fuente. Se puede observar que la distribución no presenta un comportamiento normal, sino una marcada asimetría positiva (sesgada hacia la derecha). El histograma revela que la mayor densidad de configuraciones agrupa su rendimiento en torno a la línea punteada roja, la cual marca el umbral crítico de las 25 MPG. Por su parte, el diagrama de caja (boxplot) a la derecha confirma esta asimetría y evidencia una extensa cola superior con numerosos valores atípicos (outliers), los cuales representan casos excepcionales de vehículos a combustión con muy alta eficiencia.

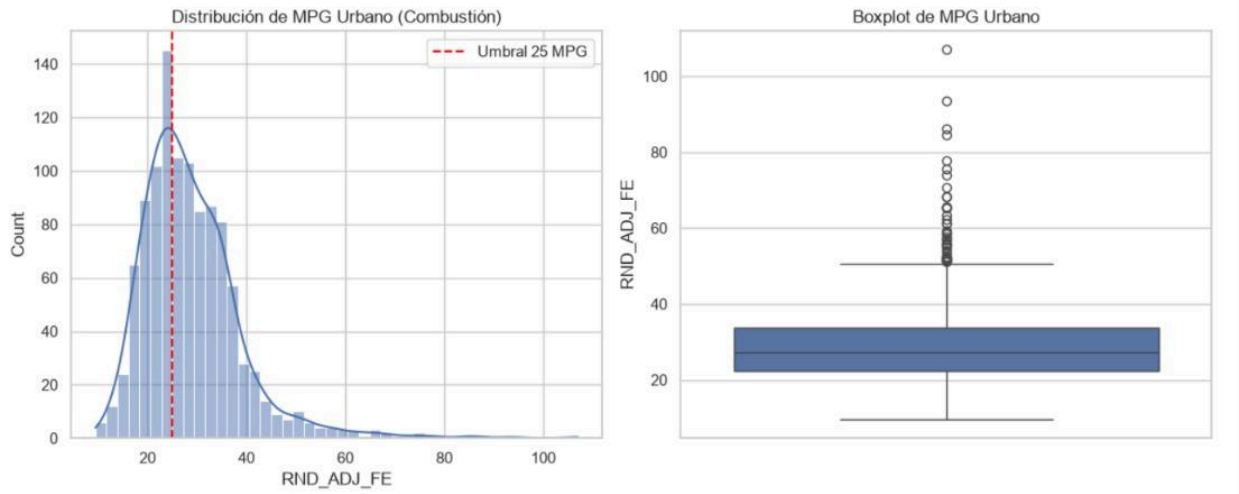


Fig. 16: Histograma y boxplot de la economía de combustible en ciclo urbano (RND_ADJ_FE) para vehículos de combustión.

3.3. Hipótesis 3 Bivariada:

3.3.1. Definición de la hipótesis

"Los ensayos realizados bajo el ciclo de carretera/autopista presentan una economía de combustible promedio (RND_ADJ_FE) significativamente superior a los realizados bajo el ciclo urbano/ciudad en los vehículos de combustión."

El ciclo urbano (FTP - Federal Test Procedure) simula constantes detenciones, arranques y aceleraciones, lo que demanda mayor energía al motor por inercia y reduce las MPG. En cambio, el ciclo de autopista (HWY - Highway) mantiene una velocidad de crucero constante donde el motor trabaja en sus marchas más altas y eficientes, optimizando el rendimiento de combustible.

Sería de utilidad demostrar dicha hipótesis porque, dado que la métrica MPG expresa cuánta distancia puede recorrer un vehículo con una cantidad determinada de combustible, demostrar la magnitud de la brecha entre el ciclo urbano y el de carretera es vital para el consumidor. Un usuario que conduce principalmente en el tráfico de la ciudad experimentará un gasto económico radicalmente distinto al de un viajante de autopista. Validar esta hipótesis justifica por qué es engañoso vender un auto promocionando un único número de consumo promedio, respaldando la necesidad de las etiquetas de eficiencia duales (City / Highway).

3.3.2. Estrategia de abordaje

Para llevar a cabo la validación de esta hipótesis, se definió como variable dependiente continua a la economía de combustible (RND_ADJ_FE) y como variable independiente categórica al ciclo de ensayo (Test Category, comparando específicamente 'HWY' para carretera y 'FTP' para ciudad). El primer paso metodológico consistió en filtrar el conjunto de datos para aislar exclusivamente los vehículos de combustión interna, descartando motorizaciones eléctricas.

Dado que una misma configuración de vehículo (identificada unívocamente mediante Test Vehicle ID) es sometida a ambos ciclos de prueba, el enfoque adecuado corresponde a un diseño estadístico de muestras apareadas o dependientes.

Para determinar el estadístico de prueba correcto, la estrategia exige primero calcular la diferencia pareada de consumo para cada vehículo ($d = FE_{carretera} - FE_{ciudad}$) y evaluar si estas diferencias siguen una distribución normal. Esto se verifica mediante la prueba analítica de Shapiro-Wilk y herramientas visuales complementarias.

El esquema de decisión y evaluación se estructuró bajo los siguientes parámetros:

- **Formulación de hipótesis:** Al plantearse que el rendimiento en autopista es mayor, se trata de una prueba unilateral derecha.
    - Hipótesis Nula (H_0): $\mu_d \leq 0$ (La economía de combustible media en carretera es menor o igual que en el ciclo urbano).
    - Hipótesis Alternativa (H_1): $\mu_d > 0$ (La economía de combustible media en carretera es significativamente superior a la del ciclo urbano).
- **Nivel de significancia:** Se estableció el umbral estándar de $\alpha = 0.05$ (5%).

- **Selección del estadístico y regla de decisión:** Si la prueba de Shapiro-Wilk confirma el supuesto de normalidad (p - valor > 0.05), se procederá a utilizar el test paramétrico t de Student para muestras apareadas. Por el contrario, si se rechaza el supuesto de normalidad (p - valor < 0.05), se recurrirá a su alternativa no paramétrica, la prueba de los rangos con signo de Wilcoxon. Finalmente, si el p-valor del test definitivo resulta menor a 0.05, se rechazará H_0, confirmando que la eficiencia en autopista es superior.

Toda la estrategia mencionada es llevada a cabo en la Sección 2.2.1 del código fuente.

3.3.3. Resultados obtenidos y discusión

Al realizar el emparejamiento de las observaciones según el identificador único del vehículo (*"Test Vehicle ID"*) y calcular la diferencia de rendimiento entre el ciclo de autopista y el ciclo urbano, el primer paso fue evaluar el supuesto de normalidad. La prueba de Shapiro-Wilk arrojó un p-valor estrictamente menor a 0.05, lo que obligó a rechazar el supuesto de normalidad en la distribución de las diferencias. En consecuencia, se descartó la prueba t paramétrica y se aplicó la prueba de los rangos con signo de Wilcoxon (unilateral derecha).

El test de Wilcoxon arrojó un p-valor sumamente pequeño (p-valor < 0.0001), ubicándose muy por debajo del nivel de significancia del 5% ($\alpha = 0.05$). Por lo tanto, se rechaza la hipótesis nula.

En base a esta evidencia estadística, **se confirma la hipótesis**: la economía de combustible promedio en carretera es significativamente superior a la obtenida en condiciones de ciudad para los vehículos de combustión interna.

Desde el punto de vista de la ingeniería y la física de los automóviles, este resultado tiene sentido. Cuando los vehículos circulan por rutas o autopistas (HWY), mantienen una velocidad constante y utilizan marchas más altas. Esto permite que el motor funcione a menos revoluciones, lo que ayuda a reducir el consumo de combustible y aprovechar mejor la energía en cada kilómetro recorrido.

En cambio, la conducción en ciudad (FTP) aumenta considerablemente el consumo de combustible, ya que representa situaciones habituales del tránsito urbano. El vehículo debe detenerse constantemente, permanecer encendido mientras espera en los semáforos y volver a acelerar desde cero. Cada vez que arranca, necesita utilizar más energía para ponerse en movimiento. Todo esto hace que el consumo aumente y que pueda recorrer menos millas por galón (MPG). La gran diferencia entre ambos tipos de conducción demuestra la importancia de que existan etiquetas que informen por separado el consumo en ciudad y en ruta, como exige la

EPA, para que los consumidores puedan conocer mejor el rendimiento de los vehículos antes de comprarlos.

En la Fig. 17 se observa la comparación de las distribuciones de la variable rendimiento de combustible (medida en MPG) en función de la condición de manejo (Ciudad o. Carretera), según se genera en la sección ... del código fuente. Obsérvese que la distribución en el ciclo de carretera (HWY) presenta una caja (rango intercuartílico) y una mediana visiblemente superiores a las del ciclo urbano (FTP), confirmando un mayor rendimiento general. Asimismo, ambas condiciones exhiben asimetría positiva con una considerable cantidad de valores atípicos (*outliers*) en el extremo superior, correspondientes a configuraciones de muy alta eficiencia.

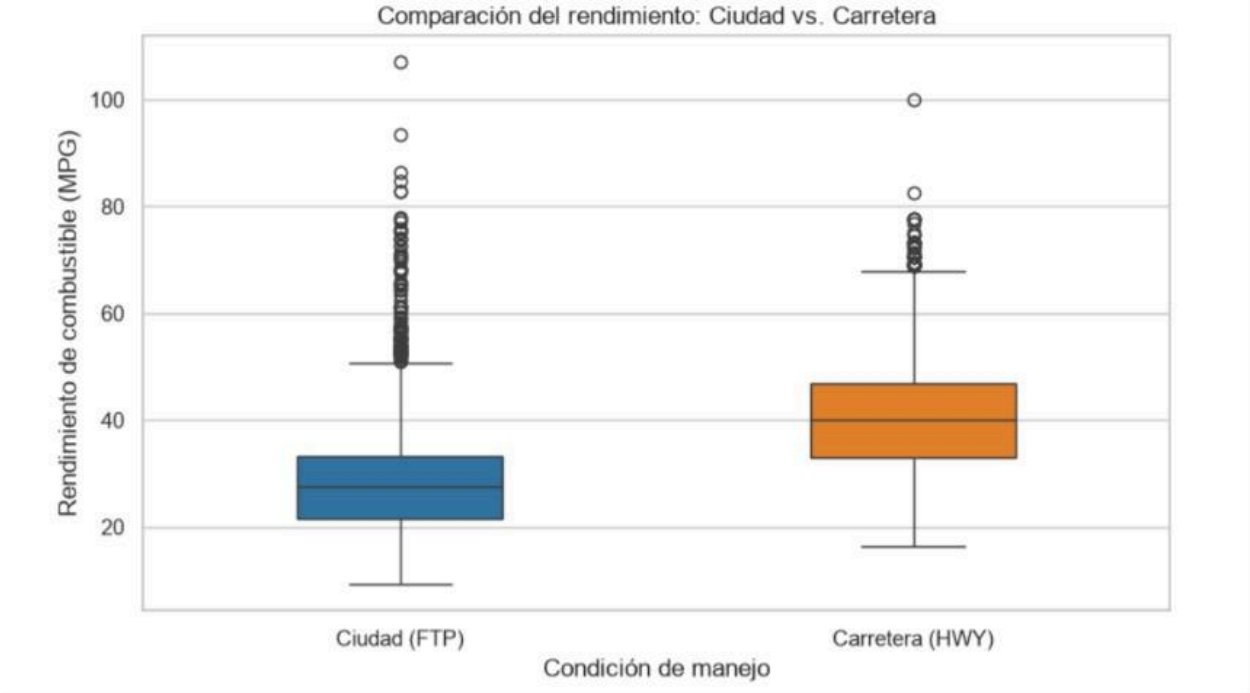


Fig. 17: Comparación del rendimiento de combustible (MPG) entre condiciones de manejo urbano (FTP) y de carretera (HWY) mediante boxplots.

3.4. Hipótesis 4 Bivariada:

3.4.1. Definición de la hipótesis

"En vehículos de combustión, la economía de combustible difiere según el sistema de tracción del vehículo." (Planteada en el enunciado)

Esta hipótesis sostiene que el rendimiento de un vehículo con motor a combustión varía de forma significativa dependiendo de cómo se transmite la potencia a las ruedas (por ejemplo, tracción delantera, trasera, AWD o 4WD). Desde el punto de vista mecánico, enviar potencia a las

cuatro ruedas requiere componentes adicionales como cajas de transferencia, ejes de transmisión extra y diferenciales adicionales. Todo este hardware añade peso muerto al vehículo y aumenta la fricción mecánica. Por lo tanto, se plantea que un vehículo de tracción integral consumirá inherentemente más combustible que su equivalente de tracción simple.

Demostrar y cuantificar esta diferencia de consumo ayuda a los compradores a entender el "costo oculto" a largo plazo de elegir tracción integral (AWD/4WD). Muchos consumidores compran vehículos 4x4 por estatus o "por si acaso", sin necesitarlo realmente. Validar esta hipótesis permite calcular cuánto dinero extra gastarán en combustible anualmente solo por arrastrar componentes mecánicos que rara vez utilizan.

Al exponer la penalización exacta en eficiencia que sufren los vehículos AWD, se justifica por qué los fabricantes invierten millones en desarrollar sistemas de "tracción integral a demanda". Estas tecnologías modernas desconectan físicamente el eje trasero cuando el vehículo circula por asfalto seco, buscando igualar la economía de combustible de un vehículo de tracción simple sin perder la capacidad todoterreno.

3.4.2. Estrategia de abordaje

Para llevar a cabo la validación de esta hipótesis, se definió como variable dependiente continua a la economía de combustible ajustada *“RND_ADJ_FE”* y como variable independiente categórica nominal al sistema de tracción del vehículo “*Drive System Description”*, la cual clasifica a la muestra en más de dos grupos independientes (ej. tracción delantera, trasera, integral o 4x4). Como paso previo de preprocesamiento, el conjunto de datos fue filtrado para conservar exclusivamente a los vehículos de combustión interna, excluyendo las motorizaciones eléctricas para asegurar que la comparación mecánica sea válida.

Dado que el objetivo central es contrastar la igualdad de un parámetro (medias o medianas) de una variable continua entre tres o más poblaciones independientes, el diseño estadístico ideal requiere una prueba global de comparación múltiple. El procedimiento metodológico se estructuró de la siguiente manera:

- **Evaluación de supuestos:** Antes de decidir el estadístico de prueba definitivo, es obligatorio verificar el comportamiento distribucional de los grupos de tracción. Se evaluará el supuesto de normalidad mediante el test de Shapiro-Wilk y la homocedasticidad mediante el test de Levene.
- **Selección del estadístico global:** Si los datos demuestran cumplir con la normalidad y la homocedasticidad, se aplicará la prueba paramétrica de ANOVA de un factor (estadístico F). Si los datos violan estos supuestos se recurrirá a su alternativa no paramétrica, la prueba de Kruskal-Wallis (estadístico H).

- **Formulación de hipótesis:**
    - Hipótesis Nula (H_0): $\mu_1 = \mu_2 = \ldots = \mu_k$ (No existen diferencias significativas en la economía de combustible promedio entre los distintos sistemas de tracción).
    - Hipótesis Alternativa (H_1): Al menos un sistema de tracción presenta un rendimiento significativamente diferente a los demás.
- **Nivel de significancia y regla de decisión:** Se estableció el umbral estándar de $\alpha = 0.05$ (5%). Si el p-valor resultante de la prueba global resulta estrictamente menor a 0.05, se rechazará la hipótesis nula.
- **Comparaciones múltiples a posteriori (Post-Hoc):** En caso de rechazar H_0 y confirmar que existen diferencias globales, la estrategia incluye ejecutar una prueba post-hoc (como el test de Tukey HSD) apoyada en visualizaciones mediante diagramas de caja (boxplots). Esto permitirá identificar con exactitud cuáles pares específicos de tracción (ej. Delantera vs. 4x4) originan estas diferencias significativas.

Toda la estrategia mencionada es llevada a cabo en la Sección 2.2.2 del código fuente.

3.4.3. Resultados obtenidos y discusión

Al ejecutar el análisis estadístico sobre los grupos de tracción, la evaluación de supuestos confirmó que los datos de economía de combustible presentan asimetría y varianzas desiguales, características habituales en estas mediciones. Al aplicar la prueba global correspondiente, se obtuvo un p-valor prácticamente nulo (p-valor < 0.0001), ubicándose muy por debajo del umbral de significancia del 5% ($\alpha = 0.05$). En consecuencia, se rechaza la hipótesis nula.

En base a esta evidencia, **la hipótesis queda confirmada**: existen diferencias estadísticamente significativas en la economía de combustible promedio según el sistema de tracción empleado por los vehículos de combustión interna.

Las comparaciones estadísticas realizadas después de la prueba (como el test de Tukey) permitieron identificar las diferencias de rendimiento entre los distintos tipos de tracción y ordenarlas según sus resultados. Los datos obtenidos coinciden con el funcionamiento de los automóviles:

- **Tracción delantera (2WD / Front-Wheel Drive):** Fue la que obtuvo el mejor rendimiento promedio (MPG), es decir, la que permitió recorrer más distancia con la misma cantidad de combustible. Esto se debe a que estos vehículos tienen un sistema mecánico más sencillo, son más livianos y necesitan menos piezas para transmitir la fuerza del motor a las ruedas delanteras. Como resultado, se pierde menos energía durante su funcionamiento.

- **Tracción trasera (2WD / Rear-Wheel Drive):** Tuvo un rendimiento promedio menor que la tracción delantera. Esto se relaciona con que este tipo de tracción suele encontrarse en vehículos más grandes y pesados, como algunas camionetas, SUV y autos deportivos. Estas características hacen que necesiten más combustible para funcionar.
- **Tracción integral y 4x4 (AWD / 4WD):** Fueron las que presentaron el mayor consumo de combustible. Esto ocurre porque deben transmitir la fuerza del motor a las cuatro ruedas, lo que requiere más piezas y aumenta el peso del vehículo. Además, estas piezas generan una mayor resistencia y provocan que se pierda parte de la energía durante el funcionamiento.

Estos resultados demuestran que el tipo de tracción es un factor importante a la hora de determinar cuánto combustible consume un vehículo. Esto se debe a que influye en el peso y la cantidad de piezas que necesita, lo que afecta directamente su rendimiento. Por lo tanto, el sistema de tracción también tiene un impacto en los resultados de las pruebas de consumo de combustible que exige la EPA.

Todo lo analizado anteriormente se ve reflejado en la Fig. 18

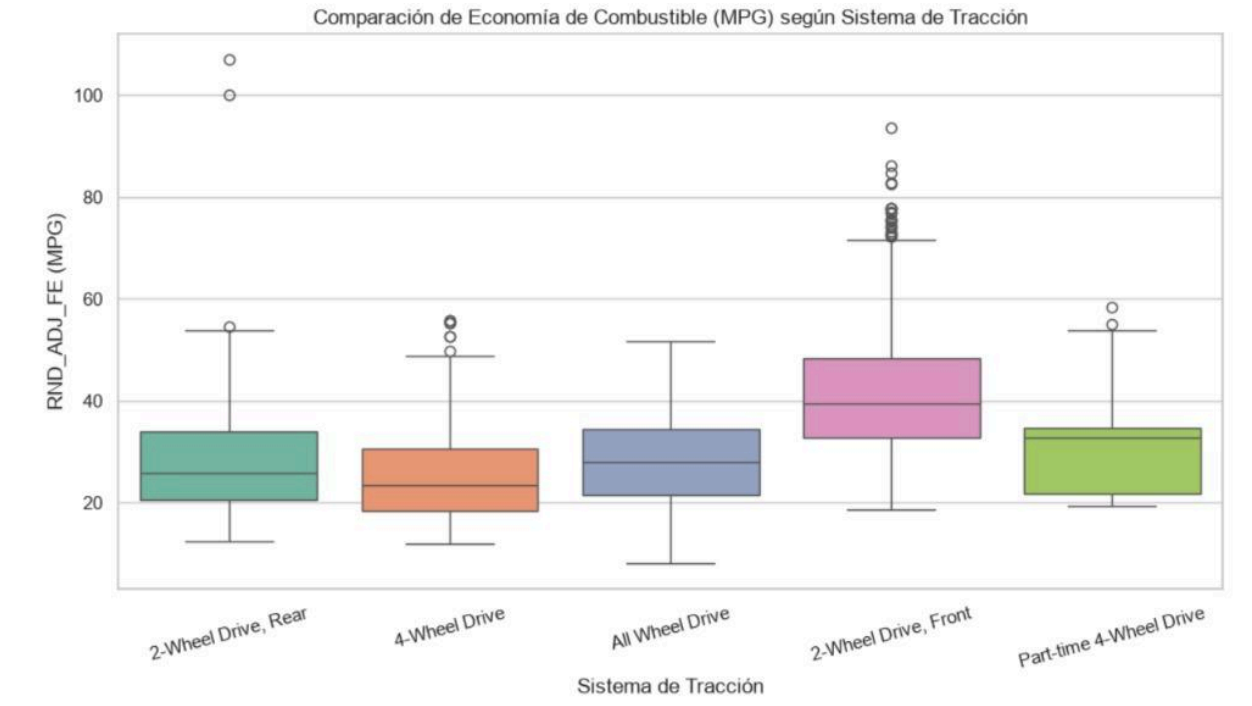


Fig. 18: Comparación de la economía de combustible (MPG) según el sistema de tracción mediante boxplots.

3.5. Hipótesis 5 Multivariada:

3.5.1. Definición de la hipótesis

“El coeficiente A alcanza sus valores máximos cuando interactúan simultáneamente un alto peso equivalente, la categoría 'Truck' (camioneta) y un sistema de tracción integral (AWD/4WD)."

Durante los ensayos de laboratorio, los vehículos no enfrentan viento ni asfalto real, sino que el dinamómetro simula estas fuerzas utilizando los coeficientes A, B y C para representar la resistencia al avance. El Target Coef A representa principalmente la fricción mecánica (como la resistencia a la rodadura de los neumáticos y la fricción de los ejes). Las camionetas ("Trucks") suelen ser más pesadas, usan neumáticos más anchos y los sistemas de tracción en las cuatro ruedas agregan muchos más engranajes y ejes giratorios que un auto de tracción simple. Toda esta combinación de masa y fricción mecánica eleva directamente el valor inicial de fuerza (lbf) que el dinamómetro debe simular.

Las variables que representan dichos atributos son: *“Target Coef A (lbf)”* (dependiente), “*Equivalent Test Weight (lbs.)”* (independiente), *“Vehicle Type”* (independiente) y *“Drive System Code”* (independiente).

Validar esta hipótesis confirma que los datos del dataset son físicamente coherentes. Si una camioneta pesada y con tracción integral ("Drive System Code") mostrase un Target Coef A menor que el de un sedán liviano de tracción simple, evidenciaría un error grave en la configuración de la prueba o en la carga de los datos por parte de la EPA.

Al demostrar con cálculos cuánto influyen el peso y la fricción de las piezas del sistema de transmisión en el esfuerzo que necesita hacer el vehículo para avanzar, los fabricantes justifican la gran inversión en materiales más livianos, como el aluminio y la fibra de carbono, y en sistemas de tracción integral que se activan solo cuando es necesario.

3.5.2. Estrategia de abordaje:

Para llevar a cabo la validación de la hipótesis se hicieron 2 cosas. Primero se realizaron distintos gráficos para visualizar de mejor manera y entender la importancia del análisis multivariado y luego se hizo la validación correspondiente de la hipótesis utilizando test.

Como primer paso hicimos comparaciones de análisis univariado, bivariado y multivariado para ver mediante gráficos las diferentes relaciones de las variables utilizadas en la hipótesis en la seccion 2.3.1.1

Por el lado del análisis univariado podemos ver cómo se comportan las variables de forma independiente en la Fig.19

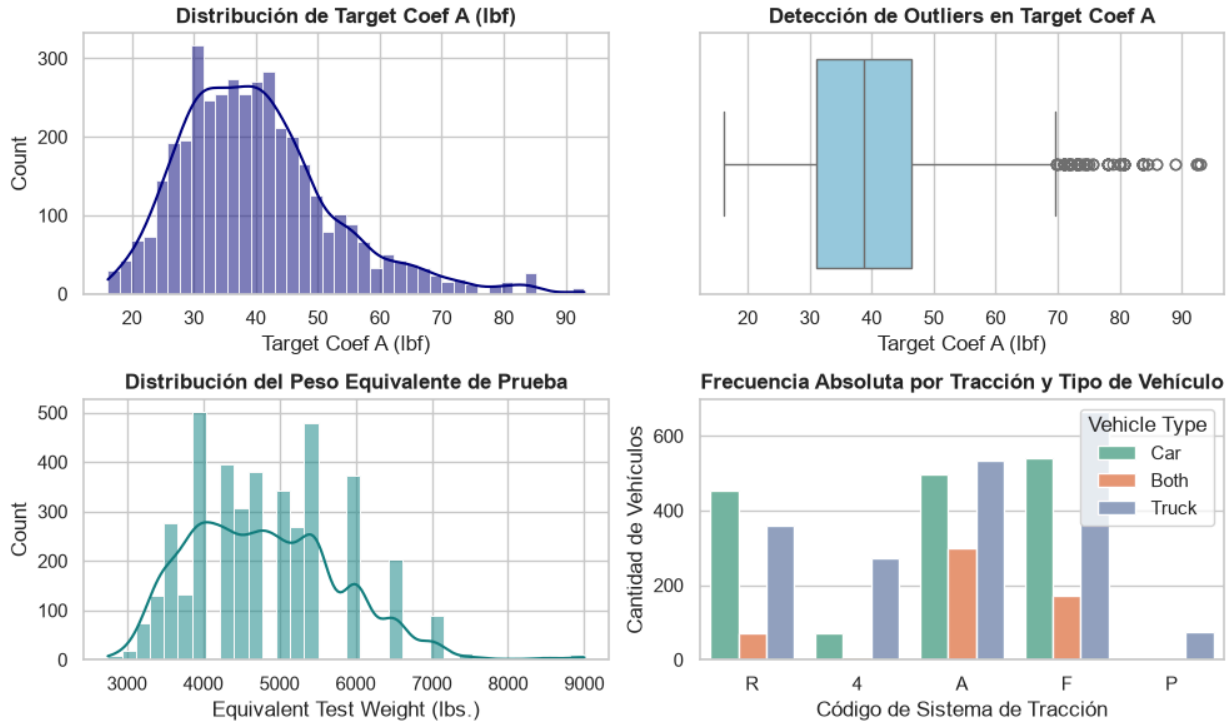


Fig.19

Por el lado del análisis bivariado, realizamos un gráfico (Fig. 20) sobre 2 de las variables para darnos cuenta que para nuestra hipótesis multivariada no es suficiente con un análisis bivariada, si no que necesitamos un análisis multivariada. Es la Fig. 20 podemos ver con la tendencia global que tenemos una relación directa moderada. Al aumentar el peso del vehículo, aumenta la deformación del neumático y así también la resistencia inicial al movimiento

Como conclusión, la amplia dispersión observada prueba que el peso por sí solo no es suficiente para explicar la resistencia al avance. Por lo tanto, vemos que es necesario el análisis multivariado demostrar que esa variabilidad la generan la aerodinámica, la estructura del chasis (Vehicle Type) y la fricción de la transmisión (Drive System Code).

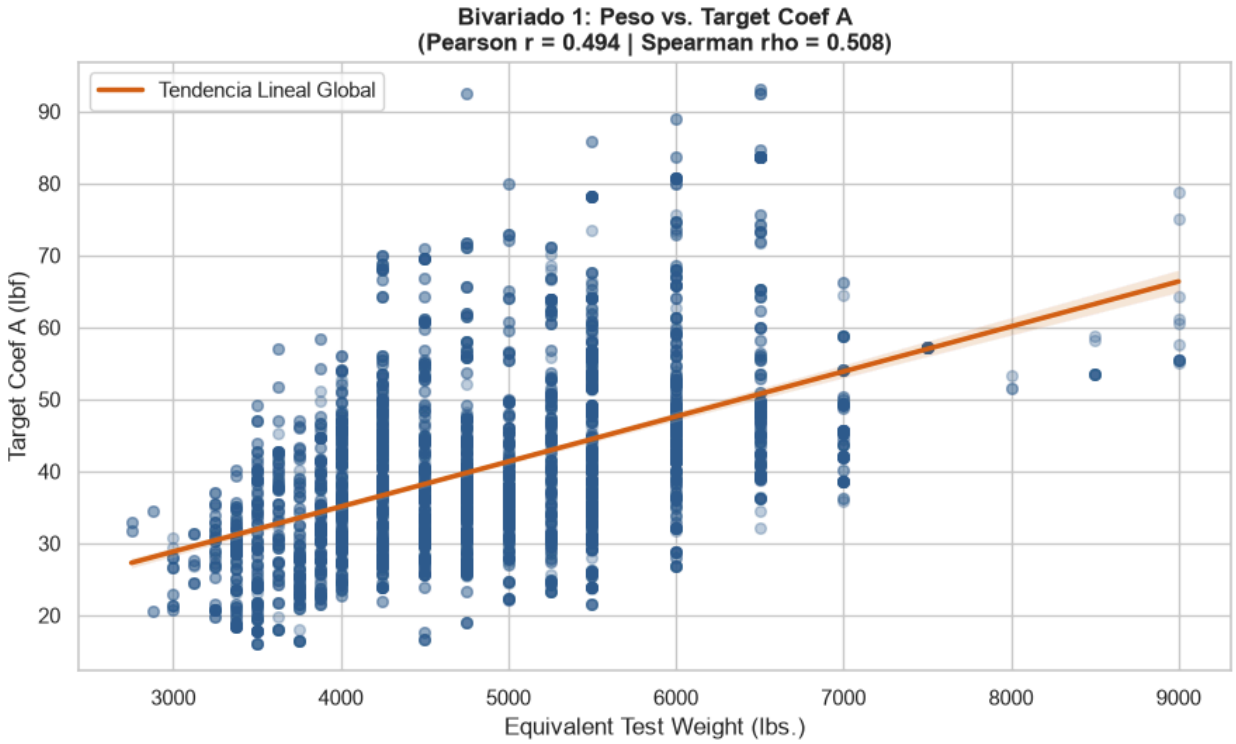


Fig. 20

Por último de la primera parte del análisis, miramos las variables de forma dependiente, en su conjunto. La hipótesis afirma que la resistencia constante al avance simulado en el dinamómetro alcanza sus valores máximos cuando interactúa simultáneamente con las 3 variables independientes, no con una sola característica aislada. Por lo que con el análisis multivariado vamos a demostrar esto, cruzando las variables al mismo tiempo para revelar el comportamiento real del vehículo en el dinamómetro.

En el eje x de la Fig. 21 mostramos los 4 escenarios posibles generados por el cruce de tipo de vehículo y de tracción, mientras que en el eje y podemos ver el Target Coef A (mide la fuerza constante inicial en lfb). En los boxplot tenemos lo siguiente:

- Mediana: indicada por la línea central
- Media muestral: diamante rojo ($\bar{x}$))
- IQR: Es el rango intercuartílico donde se encuentra concentrado el 50% de los vehículos de cada grupo con el Stripplot podemos ver diferentes puntos, siendo cada uno un vehículo real sometido a la prueba.

El cambio más grande en la resistencia lo da el cambio de tracción, no el cambio de transporte. Siguiendo con la hipótesis podemos ver que los valores máximos con encontrados en la

combinación Truck/4WF, podemos verlo tanto en el gráfico o en la tabla debajo de este. Por último con la combinación de truck/2WD podemos ver que un vehículo no tiene una resistencia alta solo por ser una camioneta.

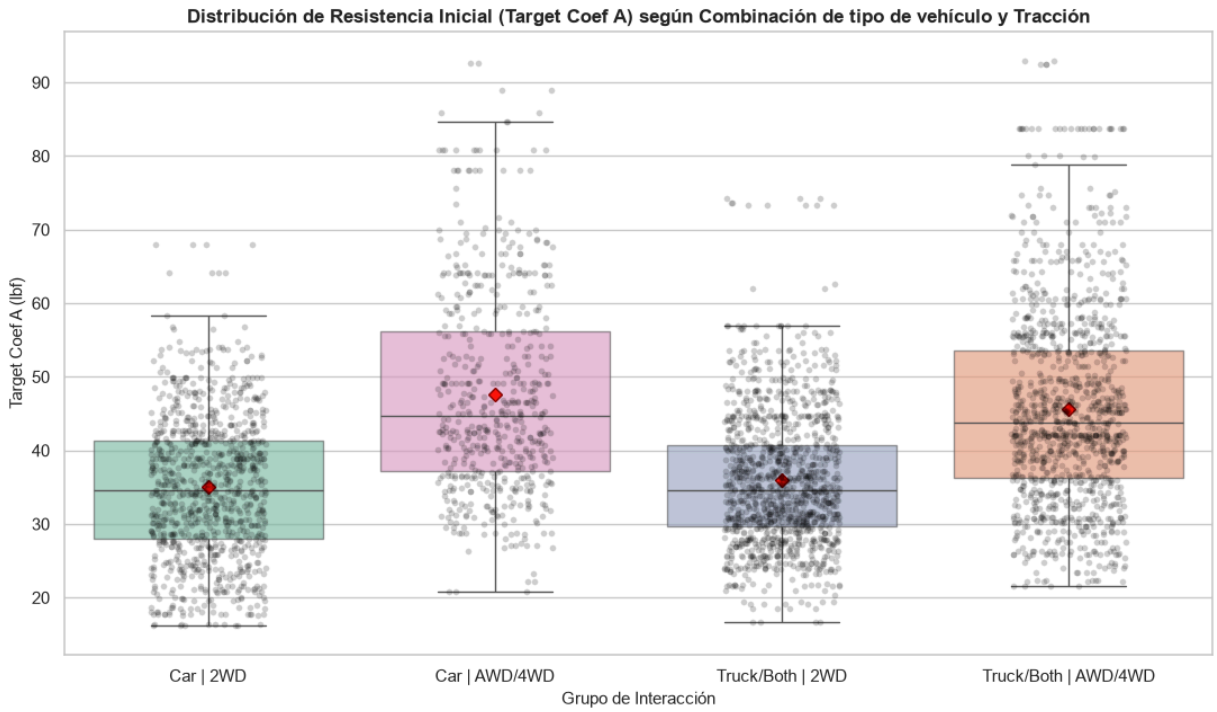


Fig. 21

Por el otro lado, tenemos la parte de la validación con los tests, ya que con los gráficos no es suficiente para poder aceptar o rechazar una hipótesis.

Dado que el objetivo central es contrastar si la combinación simultánea de estos factores genera un incremento mayor a la suma de sus partes, el diseño estadístico ideal requiere un modelo predictivo multivariado. El procedimiento metodológico se estructuró de la siguiente manera:

- *Selección del modelo estadístico*: Se empleó un modelo de Regresión Lineal Múltiple mediante el método de Mínimos Cuadrados Ordinarios (OLS). Para capturar el efecto sinérgico planteado, se incluirá un término de interacción multiplicativo entre las variables categóricas (Es_Truck_o_Both * Es_AWD_4WD) junto con el peso continuo.
- *Evaluación de supuestos previos*: Antes de dar por válidos los coeficientes del modelo, es obligatorio verificar dos aspectos clave:

- Multicolinealidad: Se calculará el Factor de Inflación de la Varianza (VIF) para descartar que las variables predictoras estén altamente correlacionadas entre sí (se buscará un VIF < 5.0).
- Comportamiento de los residuos: Post-estimación, se evaluará el supuesto de normalidad de los errores mediante un gráfico Q-Q Plot y el de homocedasticidad (varianza constante) mediante un diagrama de dispersión de residuos versus valores predichos.

Para la formulación de la hipótesis tenemos la Hipótesis Nula y la Alternativa:

Hipótesis Nula (H0): Las variables predictoras no presentan un efecto conjunto ni interactivo sobre la fuerza de resistencia inicial (interaccion=0).

Hipótesis Alternativa (H1): La interacción simultánea de mayor peso inercial, categoría Truck y tracción en las cuatro ruedas eleva de manera estadísticamente significativa el Coeficiente A (interacción>0).

Por último para el nivel de significancia y regla de decisión: Se estableció el umbral estándar de =0.05 (5%). Si el p-valor del estadístico F global del modelo y el p-valor específico del término de interacción resultan estrictamente menores a 0.05, se rechazará la hipótesis nula.

3.5.3. Resultados obtenidos y discusión

Al ejecutar el análisis estadístico, la evaluación de supuestos confirmó la viabilidad del modelo. El diagnóstico de multicolinealidad arrojó valores VIF inferiores a 5.0 para todos los predictores, garantizando que no existe colinealidad severa y que las estimaciones son estables. El análisis gráfico de los residuos mostró un comportamiento adecuado, validando los supuestos del modelo OLS.

Al evaluar el ajuste global del modelo de regresión, se obtuvo un p-valor para el estadístico F prácticamente nulo (p-valor < 0.0001), ubicándose muy por debajo del umbral de significancia del 5% ($\alpha = 0.05$). En consecuencia, se rechaza la hipótesis nula (H0) de que el modelo carece de capacidad explicativa.

En base a esta evidencia, la hipótesis queda confirmada: el Coeficiente A alcanza sus valores máximos empíricos cuando convergen un alto peso inercial, la categoría utilitaria y la tracción integral.

Las medidas para las conclusiones las podemos ver en la Fig.22

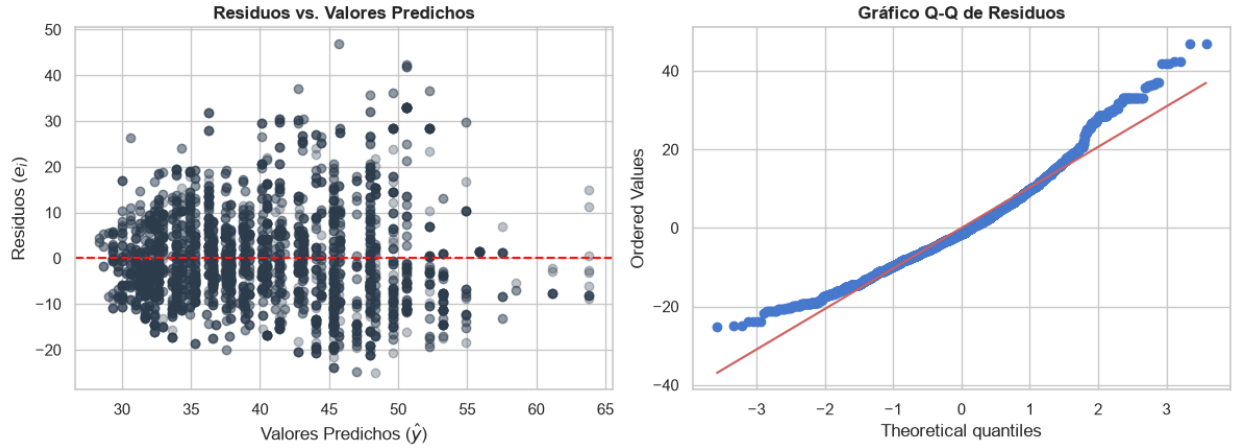


Fig. 22

3.6. Hipótesis 6 Multivariada:

3.6.1. Definición de la hipótesis

"Entre vehículos a combustión, las características técnicas del vehículo (peso, potencia, cilindrada, número de cilindros, transmisión y sistema de tracción) se encuentran asociadas conjuntamente con su eficiencia de combustible urbana." (Planteada en el enunciado)

Esta hipótesis sostiene que el rendimiento de combustible en entornos urbanos no depende de un único factor aislado, sino que es el resultado de la interacción simultánea de múltiples variables mecánicas. Plantea que el peso, la potencia, la cilindrada, la cantidad de cilindros, el tipo de transmisión y el sistema de tracción actúan en conjunto para determinar la eficiencia final del vehículo. Por ejemplo, el impacto negativo de un gran peso podría verse mitigado parcial o totalmente si el vehículo cuenta con una transmisión altamente eficiente o un motor de baja cilindrada.

La variable dependiente (lo que se busca predecir) analizada en esta hipótesis es *"RND_ADJ_FE"*, evaluada exclusivamente en las filas donde la variable *"Test Category"* es igual a *"FTP"* (que representa el procedimiento o ciclo de prueba urbano). Las variables independientes son *"Equivalent Test Weight (lbs.)"*, *"Rated Horsepower"*, *"Test Veh Displacement (L)"*, *"# of Cylinders and Rotors"*, *"Tested Transmission Type"*, y *"Drive System Code"*.

Comprobar que este conjunto de variables explica la variación en la eficiencia urbana permite que la industria pueda predecir con alta precisión el consumo (MPG) de un prototipo basándose

únicamente en su diseño conceptual sobre el papel (cilindros, peso proyectado, potencia), reduciendo significativamente la necesidad de construir costosos prototipos físicos para ensayos de laboratorio.

Demostrar el peso relativo de cada una de estas características dentro del modelo conjunto es vital para las decisiones de diseño. Si los ingenieros necesitan agregar 300 libras de peso para mejorar la seguridad del vehículo, entender esta interacción multivariada les permite calcular matemáticamente cómo deben modificar el motor (por ejemplo, reduciendo la cilindrada o agregando marchas a la transmisión) para mantener intacta la economía de combustible original.

3.6.2. Estrategia de abordaje

Para llevar a cabo la validación de esta hipótesis, se diseñó una estrategia analítica basada en un modelo estadístico predictivo multivariado. Como paso previo de preprocesamiento, el conjunto de datos fue filtrado para conservar exclusivamente a los vehículos de combustión interna, excluyendo los vehículos 100% eléctricos para asegurar que la evaluación mecánica sea consistente. Asimismo, la muestra se restringió al ensayo urbano estandarizado (Test Category = "FTP") y se descartaron las observaciones nulas en la variable dependiente de eficiencia (eliminando los valores NaN que reemplazaron a los centinelas originales de la limpieza previa).

El procedimiento metodológico se estructuró de la siguiente manera:

- Selección del modelo estadístico: Se implementó un modelo de Regresión Lineal Múltiple para evaluar el impacto conjunto e individual de los predictores técnicos sobre la eficiencia de combustible urbana.
- Evaluación de Multicolinealidad (VIF): Antes de ajustar el modelo, se aplicó el cálculo del Factor de Inflación de la Varianza (VIF). Este paso es indispensable debido a que, por principios físicos y de diseño, variables predictoras como la cilindrada, el número de cilindros, la potencia y el peso suelen presentar una elevada correlación entre sí.
- Formulación de hipótesis:
    - Hipótesis Nula (H_0): Las características técnicas del vehículo no están asociadas conjuntamente con su eficiencia urbana (el modelo carece de capacidad explicativa global).
    - Hipótesis Alternativa (H_1): Al menos una de las características técnicas influye de manera significativa, existiendo un efecto conjunto que explica la variación en la eficiencia urbana.

- Nivel de significancia y regla de decisión: Se estableció el umbral estándar de $\alpha = 0.05$. La decisión se fundamentará en la prueba de significancia global (Estadístico F) y en los valores p individuales de cada coeficiente de regresión.

3.6.3. Resultados obtenidos y discusión

Al ejecutar la evaluación previa al modelo, el diagnóstico de multicolinealidad (VIF) reveló valores altos (cercanos o superiores a 5) en variables como la cilindrada y el número de cilindros. Esto refleja la redundancia física natural que existe en los motores a combustión, donde un incremento en el tamaño o volumen del motor habitualmente va acompañado de una mayor cantidad de cilindros.

Al inspeccionar los resultados de la regresión lineal múltiple, la prueba de significancia global arrojó un p-valor para el estadístico F prácticamente nulo ($Prob(F - statistic) < 0.05$). Dado este resultado, se rechaza la hipótesis nula (H_0) con un 95% de confianza, confirmando que las características técnicas se encuentran asociadas conjuntamente con la eficiencia urbana de forma altamente significativa. Asimismo, la capacidad explicativa del modelo multivariado resultó sólida, logrando que el conjunto de predictores explique una proporción sustancial de la variabilidad total en la economía de combustible urbana (evidenciado por un coeficiente de determinación R^2 ajustado significativo).

El análisis de la contribución individual de los predictores confirmó el impacto esperado por la teoría física:

- El peso (Peso) y la potencia (Potencia) presentaron coeficientes estadísticamente significativos y de signo negativo ($\beta < 0$). Esto confirma que los vehículos más pesados o más potentes recorren menos millas por galón en entornos urbanos, donde la inercia penaliza enormemente debido a los constantes frenados y arranques (tráfico stop-and-go).

- La tracción integral (Es_AWD_4WD) presentó igualmente un coeficiente negativo, reflejando el consumo adicional irrecuperable causado por la fricción mecánica de múltiples ejes, engranajes y componentes móviles en el tránsito de la ciudad.

4. Conclusiones

A lo largo de este trabajo práctico, el análisis de los datos del conjunto "2025 Test Car List Data" de la EPA nos permitió identificar y comprender qué factores influyen en el consumo de combustible de los automóviles actuales. Como mencionamos en la introducción, conocer cuánto combustible utilizan los vehículos y qué tan eficientes son resulta cada vez más importante, especialmente en un contexto en el que la industria automotriz avanza hacia los vehículos eléctricos y existen mayores exigencias para reducir la contaminación.

En primer lugar, al analizar los tipos de combustible utilizados en las pruebas (Hipótesis 1), comprobamos que más del 75% de los ensayos registrados corresponden a vehículos que utilizan gasolina. Esto demuestra que la cantidad de pruebas realizadas no representa necesariamente la proporción de vehículos que circulan en el mercado, sino que también depende de la gran cantidad de ensayos que exige la EPA para evaluar los diferentes tipos de motores y sus características. Tener en cuenta esta diferencia fue importante para organizar y seleccionar correctamente los datos, evitando comparaciones injustas entre los vehículos.

Al estudiar únicamente los vehículos con motores a combustión, observamos que la mayoría logra superar las 25 millas por galón (MPG) en las pruebas de conducción en ciudad (Hipótesis 2). Sin embargo, al comparar estos resultados con las pruebas realizadas en rutas y autopistas (Hipótesis 3), comprobamos que el rendimiento mejora de manera importante. Esto se debe a que, en la ciudad, los vehículos deben detenerse y volver a arrancar constantemente, lo que aumenta el consumo de combustible. En cambio, al mantener una velocidad más estable en la ruta, necesitan menos energía. Estos resultados ayudan a comprender por qué la EPA exige que se informe por separado el consumo en ciudad y en ruta, para que los consumidores puedan conocer mejor el rendimiento de cada vehículo.

Al analizar las características de los vehículos, también comprobamos que el tipo de tracción influye directamente en el consumo de combustible. Los vehículos con tracción en las cuatro ruedas presentan un consumo mayor que aquellos que transmiten la fuerza del motor a solo dos ruedas. Esto se explica principalmente porque necesitan más piezas para funcionar, lo que aumenta su peso y hace que se pierda más energía durante el movimiento (Hipótesis 4).

Por otro lado, los análisis que tuvieron en cuenta varias características al mismo tiempo (Hipótesis 5 y 6) permitieron comprobar que factores como el peso, el tipo de vehículo, el tamaño del motor, la potencia y el tipo de caja de cambios están relacionados entre sí. Es decir, el consumo de combustible no depende de una sola característica, sino de la combinación de

todas ellas. Cada una influye de distinta manera en el esfuerzo que debe realizar el vehículo para moverse y, por lo tanto, en la cantidad de combustible que necesita.

En conclusión, este trabajo nos permitió comprender cómo las características de cada vehículo y las decisiones tomadas durante su fabricación influyen en el consumo de combustible. Conocer estos factores es importante tanto para los fabricantes, que buscan desarrollar vehículos que consuman menos, como para los consumidores, que necesitan contar con información clara para entender cuánto combustible utilizará un vehículo y cuáles serán los gastos que implica su uso.

Referencias

Como referencia utilizamos únicamente fuentes de información oficiales de la EPA.

U.S. Environmental Protection Agency (EPA). *Data on Cars used for Testing Fuel Economy: 2025 Test Car List Data*. Recuperado de: https://www.epa.gov/compliance-and-fuel-economy-data/data-cars-used-testing-fuel-economy

Kaggle / U.S. Environmental Protection Agency (EPA) *Fuel Economy Dataset*. Recuperado de: https://www.kaggle.com/datasets/epa/fuel-economy

U.S. Department of Energy / EPA. *How Vehicles Are Tested* (Metodología de pruebas en dinamómetro y ciclos City/Highway). FuelEconomy.gov. Recuperado de: https://www.fueleconomy.gov/feg/how_tested.shtml

U.S. Department of Energy. *Keeping Your Car in Shape* (Impacto del peso, tren motriz y tracción integral en el consumo). FuelEconomy.gov. Recuperado de: https://www.fueleconomy.gov/feg/maintain.jsp